

ESTUDIO COMPARATIVO DE MODELOS DE
VISIÓN ARTIFICIAL PARA EL
RECONOCIMIENTO FACIAL DE EMOCIONES
COMPARATIVE STUDY OF COMPUTER VISION
MODELS FOR FACIAL EMOTION RECOGNITION



TRABAJO FIN DE MÁSTER
CURSO 2025-2026

AUTOR
LIDIA GONZÁLEZ MARTÍN

DIRECTOR
FERNANDO CARLOS LÓPEZ HERNÁNDEZ
CLARA ISABEL LÓPEZ GONZÁLEZ

MÁSTER EN INTELIGENCIA ARTIFICIAL
FACULTAD DE INFORMÁTICA
UNIVERSIDAD COMPLUTENSE DE MADRID

ESTUDIO COMPARATIVO DE MODELOS DE
VISIÓN ARTIFICIAL PARA EL
RECONOCIMIENTO FACIAL DE EMOCIONES
COMPARATIVE STUDY OF COMPUTER VISION
MODELS FOR FACIAL EMOTION RECOGNITION

TRABAJO DE FIN DE MÁSTER EN INTELIGENCIA ARTIFICIAL
DEPARTAMENTO DE INGENIERÍA DE SOFTWARE E INTELIGENCIA
ARTIFICIAL

AUTOR
LIDIA GONZÁLEZ MARTÍN

DIRECTOR
FERNANDO CARLOS LÓPEZ HERNÁNDEZ
CLARA ISABEL LÓPEZ GONZÁLEZ

CONVOCATORIA: JUNIO 2026
CALIFICACIÓN: NOTA

MÁSTER EN INTELIGENCIA ARTIFICIAL
FACULTAD DE INFORMÁTICA
UNIVERSIDAD COMPLUTENSE DE MADRID

19 DE JUNIO DE 2026

DEDICATORIA

A mi madre, que siempre cree que puedo.

Te quiero caballa.

RESUMEN

Título: Estudio comparativo de modelos de visión artificial para el reconocimiento facial de emociones

Este trabajo realiza un estudio comparativo de cuatro aproximaciones con distinto nivel de complejidad para reconocimiento de expresiones faciales (FER), un método clásico basado en la extracción de características mediante HOG+SVM, dos arquitecturas convolucionales profundas (ResNet50 y EfficientNetB3) y un modelo basado en mecanismos de atención (ViT-B/16). Todos los modelos fueron entrenados mediante transfer learning sobre un subconjunto del dataset RAF-DB y evaluados utilizando métricas balanceadas, medidas de eficiencia computacional y técnicas de explicabilidad basadas en Grad-CAM, Attention Rollout y proyecciones t-SNE.

Los resultados muestran que EfficientNetB3 obtiene el mejor rendimiento global (F1-Macro de 0.656, Balanced Accuracy de 0.682) con latencia moderada, siendo también el modelo que muestra haber aprendido patrones faciales más coherentes con el sistema de codificación de la acción facial (FACS). ViT-B/16 alcanza resultados comparables con una latencia inferior mientras que ResNet50 y HOG+SVM presentan menor coherencia con el FACS, y peor rendimiento global.

El estudio pone de manifiesto que la evaluación de sistemas FER no debe basarse únicamente en métricas de rendimiento, sino considerar conjuntamente aspectos de eficiencia, robustez e interpretabilidad. Los resultados obtenidos sitúan a EfficientNetB3 como la alternativa más equilibrada entre las arquitecturas analizadas para escenarios de aplicación reales.

Palabras clave

Reconocimiento de expresiones faciales (FER), Sistema de Codificación de la Acción Facial (FACS), visión artificial, aprendizaje profundo, transfer learning, Vision Transformer, explicabilidad, Grad-CAM.

ABSTRACT

Title: Comparative Study of Computer Vision Models for Facial Emotion Recognition

This paper presents a comparative study of four approaches with varying levels of complexity for facial expression recognition (FER): a classical method based on feature extraction using HOG+SVM, two deep convolutional architectures (ResNet50 and EfficientNetB3), and a model based on attention mechanisms (ViT-B/16). All models were trained using transfer learning on a subset of the RAF-DB dataset and evaluated using balanced metrics, computational efficiency measures and explainability techniques based on Grad-CAM, Attention Rollout and t-SNE projections.

The results show that EfficientNetB3 achieves the best overall performance (F1-Macro of 0.656, Balanced Accuracy of 0.682) with moderate latency; it is also the model that has been shown to have learnt facial patterns most consistent with the Facial Action Coding System (FACS). ViT-B/16 achieves comparable results with lower latency, whilst ResNet50 and HOG+SVM show less consistency with FACS and poorer overall performance.

The study highlights that the evaluation of FER systems should not be based solely on performance metrics, but should also take into account aspects of efficiency, robustness and interpretability. The results obtained show that EfficientNetB3 is the most balanced option among the architectures analysed for real-world application scenarios.

Keywords

Facial Expression Recognition (FER), Facial Action Coding System (FACS), computer vision, deep learning, transfer learning, Vision Transformer, explainability, Grad-CAM.

ÍNDICE DE CONTENIDOS

Capítulo 1 - Introducción	1
1.1 Motivación	1
1.2 Objetivos.....	2
1.3 Plan de trabajo	3
Capítulo 2 - Estado de la cuestión	5
2.1 Expresión facial de las emociones básicas y el sistema FACS	5
2.2 Aplicaciones	7
2.3 Datasets	8
2.3.1 JAFFE	8
2.3.2 AffectNet	9
2.3.3 RAF_DB	10
2.3.4 FER2013	11
2.3.5 CK+	11
2.4 Enfoques Clásicos	13
2.4.1 Extracción manual de características	13
2.4.2 Clasificadores tradicionales	16
2.5 Arquitecturas profundas	17
2.5.1 ResNet	18
2.5.2 EfficientNet.....	19
2.5.3 Transformers	20
Capítulo 3 - Revisión de la tecnología.....	22
3.1 Redes Neuronales Convolucionales (CNNs)	22
3.2 Transfer Learning	24

3.3 Técnicas de Balanceo	25
3.4 Robustez	26
3.5 Explicabilidad.....	27
Capítulo 4 - Metodología de investigación	32
4.1 Selección del dataset	32
4.2 Selección de modelos.....	33
4.3 Pipeline	35
4.3.1 Tratamiento del Dataset.....	35
4.3.2 Métricas de evaluación	37
4.3.3 Preprocesamiento.....	38
4.3.4 Entorno de ejecución	39
4.3.5 Protocolo experimental	39
4.3.6 Robustez.....	41
4.3.7 Técnicas de Explicabilidad.....	43
Capítulo 5 - Análisis de resultados.....	46
5.1 Rendimiento	46
5.2 Análisis por clase	48
5.3 Análisis matrices de confusión	49
5.4 Análisis de eficiencia	50
5.5 Robustez	52
Capítulo 6 - Análisis de Explicabilidad	55
6.1 Explicabilidad en EfficientNetB3	55
6.2 Explicabilidad en ResNet50.....	57
6.3 Explicabilidad en ViT-B/16	59
6.4 Explicabilidad en HOG+SVM	61

6.5 Conclusión de explicabilidad basada en Grad-CAM y Attention-RollOut	63
6.6 Distribución en el espacio de representación	63
6.7 Prototipos y críticas	66
Capítulo 7 - Conclusiones y trabajo futuro	67
Bibliografía.....	77
Apéndices	85

ÍNDICE DE FIGURAS

Figura 1 Representación de Unidades de Activación (AU) por emoción.....	6
Figura 2 Muestras de emociones en el dataset JAFFE	9
Figura 3 Ejemplos de imágenes etiquetadas del dataset AffectNet [13]	10
Figura 4 Muestras etiquetadas del dataset RAF-DB [15]	10
Figura 5 Ejemplos de imágenes del dataset FER2013 [17]	11
Figura 6 Ejemplos de imágenes de dataset CK+ [19]	12
Figura 7 Proceso de codificación en LBP [30].....	14
Figura 8 Proceso de aplicación de filtros Gabor [30].....	15
Figura 9 División de clases SVM mediante hiperplano.....	16
Figura 10 Arquitectura general de ViT [42].....	21
Figura 11 Relación Explicabilidad – Accuracy [48]	28
Figura 12 Mapa Grad-CAM para una predicción de la emoción sorpresa	29
Figura 13 Representación de prototipos y críticas, ejemplo clase Happy	31
Figura 14 Distribución del dataset RAF-DB.....	33
Figura 15 Distribución Conjuntos del Dataset	35
Figura 16 Tipos de perturbación para analizar la robustez.....	42
Figura 17 Comparativa general de explicabilidad en cada modelo analizado.....	44
Figura 18 Resultados en porcentaje de degradación por modelo y alteración	52
Figura 19 Grad-CAM EfficientNet, aciertos por emoción	55
Figura 20 Grad-CAM ResNet50, aciertos por emoción	58
Figura 21 Grad-CAM ViT-B/16, aciertos por emoción	59
Figura 22 Attention-RollOut en ViTranformer	60
Figura 23 Representación de gradientes HOG+SVM, aciertos por emoción	62

Figura 24 Distribución de clases y prototipos EfficientNetB3.....	64
Figura 25 Distribución clases y prototipos en ResNet.....	65
Figura 26 Distribución de clases ViT-B/16	65

ÍNDICE DE TABLAS

Tabla 1 Significado de AUs y sus emociones [5]	7
Tabla 2 Comparativa de los datasets FER analizados	13
Tabla 3 Comparativa de arquitecturas CNNs clásicas utilizadas en visión artificial [19] ..	24
Tabla 4 Resultados Globales para cada modelo sobre RAF-DB.....	47
Tabla 5 Resultados F1 Macro por emoción y modelo evaluado	48
Tabla 6 Comparativa de eficiencia computacional de los modelos evaluados	50

Capítulo 1 - Introducción

1.1 Motivación

El reconocimiento de expresiones faciales (Facial Expression Recognition, FER) es una tarea consolidada dentro de la Visión Artificial que abarca un amplio conjunto de aproximaciones, que van desde métodos clásicos, basados en técnicas de extracción manual de características y su clasificación, hasta enfoques más complejos fundamentados en técnicas de aprendizaje profundo.

Diversos elementos de la comunicación verbal y no verbal nos resultan útiles para identificar emociones. En concreto, las expresiones faciales son especialmente informativas, ya que aportan información sobre el estado de ánimo de una persona. En este contexto, y junto con el auge de la inteligencia artificial (IA), las máquinas han adquirido la capacidad de analizar y clasificar emociones faciales.

Estos avances presentan, a su vez, una gran relevancia en el ámbito social al facilitar la identificación de emociones, un aspecto clave para la comunicación. En particular, esta tecnología resulta de utilidad para personas con dificultades en la interacción emocional, como personas con discapacidad visual o trastornos del espectro autista, facilitando así su interacción con el entorno.

Este contexto motiva la necesidad de analizar qué enfoques actuales resultan más adecuados y en concreto, este proyecto tiene como objetivo realizar una comparación detallada de diferentes aproximaciones técnicas para la clasificación de emociones faciales, empleando tanto técnicas de visión artificial más tradicionales basadas en la extracción de características como técnicas más modernas de aprendizaje profundo, con el fin de analizar sus ventajas y limitaciones. Además, puesto que todos los modelos que se van a plantear presentan un preentrenamiento sobre ImageNet, este estudio permite analizar la capacidad que tienen diferentes arquitecturas para generalizar mediante transfer learning hacia tareas complejas de un dominio específico con datos limitados, como es el caso del reconocimiento facial de emociones.

1.2 Objetivos

El objetivo principal de este trabajo es realizar un estudio comparativo de distintas arquitecturas de aprendizaje profundo aplicadas al reconocimiento de emociones faciales sobre imágenes estáticas, evaluando su rendimiento, eficiencia y comportamiento.

Aunque el reconocimiento de emociones es más realista en secuencias de vídeo con información temporal, este trabajo se enfoca en evaluar la capacidad de los modelos para reconocer patrones faciales estáticos, aislando esta capacidad de cualquier variable temporal. Además, dado que muchos sistemas de video procesan la información frame a frame, los resultados obtenidos en imágenes estáticas son aplicables a análisis de secuencias de video.

Para alcanzar este objetivo general, se plantean los siguientes objetivos específicos:

1. **Revisión del estado del arte.** Analizar el estado del arte referente al reconocimiento de emociones faciales mediante técnicas de visión artificial y aprendizaje profundo.
2. **Definición de un baseline clásico.** Con la finalidad de contextualizar los resultados obtenidos y evidenciar la necesidad y la mejora que representan las arquitecturas de aprendizaje profundo se incluirá como baseline un método de visión artificial clásico basado en la extracción manual de características y su posterior clasificación.
3. **Selección de arquitecturas representativas.** Seleccionar arquitecturas representativas para el estudio comparativo, siguiendo una progresión que abarque desde métodos clásicos de extracción manual de características hasta arquitecturas modernas de aprendizaje profundo, con el fin de realizar un estudio comparativo que permita contextualizar su rendimiento, eficiencia y comportamiento en el reconocimiento de emociones faciales.
4. **Implementación y evaluación del rendimiento.** Implementar y entrenar arquitecturas seleccionadas mediante estrategias de *feature extraction* y *fine-tuning*. Los modelos seleccionados parten de un preentrenamiento común sobre ImageNet, lo que permite aislar el impacto de la arquitectura como variable independiente y analizar

a su vez la capacidad de generalización para tareas complejas con datos limitados como el reconocimiento facial de emociones. Posteriormente se evaluó el rendimiento de los modelos mediante métricas de clasificación, así como criterios de eficiencia computacional y robustez.

5. **Análisis de explicabilidad.** Las arquitecturas basadas en aprendizaje profundo presentan una interpretabilidad limitada debido a su naturaleza de caja negra. Se analizará el proceso de toma de decisiones de los modelos mediante técnicas de explicabilidad *post-hoc*. En particular, se emplearán métodos visuales como Grad-CAM y mapas de atención para identificar qué regiones faciales influyen en las predicciones realizadas por cada arquitectura. Finalmente, se compararán los resultados obtenidos, identificando ventajas y limitaciones de cada modelo.

1.3 Plan de trabajo

El desarrollo de este trabajo se ha estructurado según un enfoque dividido en fases con la finalidad de alcanzar los objetivos planteados.

En primer lugar, se realizó una revisión del estado del arte, analizando investigaciones previas relacionadas con el reconocimiento de expresiones faciales. Este análisis permitió comprender el contexto actual y justificar la selección del dataset y técnicas que fueron empleadas y comparadas a lo largo del estudio.

Posteriormente, se realizó la implementación de cada técnica seleccionada, comenzando por un preprocesamiento común que permita una comparación justa. Únicamente se realizó el preprocesamiento específico estrictamente necesario para el correcto funcionamiento de cada modelo.

Cada modelo fue entrenado con *feature-extraction* y *fine-tuning*, partiendo de pesos preentrenados en ImageNet, descartando aquellos preentrenados específicos de FER con la finalidad de garantizar condiciones equivalentes y estudiar la capacidad de cada modelo para adaptarse desde un dominio general a uno más específico y complejo.

Finalmente, en base a los resultados obtenidos se analizó y comparó el rendimiento, eficiencia y robustez ante artefactos que deterioran la imagen de cada

modelo junto con su explicabilidad con la finalidad de identificar patrones de comportamiento y diferencias significativas entre cada arquitectura evaluada.

Toda la información sobre el entrenamiento, la implementación y los resultados obtenidos en Apéndice B - .

Capítulo 2 - Estado de la cuestión

El Reconocimiento de Emociones Faciales (Facial Expression Recognition, FER) [1] constituye una línea de investigación relevante dentro del ámbito de la visión artificial y la interacción persona-máquina, con aplicaciones en dominios como los videojuegos, los sistemas de recomendación, la monitorización de la salud mental y del estrés, así como en sistemas de apoyo a la comunicación y la asistencia social. La capacidad de identificar automáticamente el estado emocional de un individuo a partir de su expresión facial permite desarrollar sistemas adaptativos y empáticos centrados en el usuario.

2.1 Expresión facial de las emociones básicas y el sistema FACS

Gran parte de las investigaciones en FER se han centrado tradicionalmente en la identificación de un conjunto reducido de emociones básicas, comúnmente definidas por Ekman [2] como ira, asco, miedo, felicidad, tristeza, sorpresa y una emoción adicional de emoción neutra agregada para completar el espacio de clasificación en tareas computacionales. En este contexto, comprender las diferentes categorías de expresiones faciales de emoción es esencial para el diseño de modelos computacionales capaces de generalizar más allá de elementos específicos.

Con el objetivo de aportar una descripción objetiva y reproducible de los movimientos faciales, Ekman y Friesen desarrollaron el *Facial Action Coding System* (FACS), un esquema de codificación que descompone cualquier expresión facial en combinaciones de unidades de acción elementales (Action Units - AU) [3],[4]. Cada AU se corresponde con la contracción de uno o varios grupos musculares faciales, lo que permite describir de forma precisa qué regiones del rostro se contraen con cada emoción.

Desde el punto de vista de la visión artificial y en el contexto de este trabajo, la representación basada en AUs permite una descomposición estructurada e interpretable de cada emoción, de esta forma, por ejemplo, la felicidad, en concreto, la sonrisa genuina (sonrisa Duchenne) se caracteriza principalmente por la activación del AU 6 (elevación de los pómulos), el AU 12 (elevación del labio en la comisura), AU 24

(comprensión labial). Es importante mencionar que, si bien hay AUs que se activan siempre para emociones específicas, algunos pueden o no presentarse en todas las ocasiones.

En la Figura 1, se muestra la correspondencia entre las emociones básicas y sus Aus asociadas. Posteriormente, la Tabla 1 recoge la base muscular activada por cada AU y las emociones correspondientes que lo presentan.




Figura 1 Representación de Unidades de Activación (AU) por emoción

Unidad de Activación	Base Muscular	Emociones que lo presentan
AU 1	"Frontalis, Pars Medialis"	Tristeza, Sorpresa y Miedo
AU 2	"Frontalis, Pars Lateralis"	Sorpresa, Miedo
AU 4	"Depressor Glabellae"	Tristeza, Ira, Asco, Miedo
AU 5	"Levator Papebrae Superioris"	Sorpresa, Miedo
AU 6	"Orbicularis oculi, Pars Orbitalis"	Felicidad, Tristeza
AU 7	"Orbicularis oculi, Pars Palpebralis"	Ira, Asco, Miedo
AU 9	"Levator Labii Superiori, Alaque Nasi"	Asco

AU 10	“Levator Labii, Superioris, Caput Infraorbitalis”	Asco
AU 12	“Zygomatic Major”	Felicidad
AU 15	“Triangularis”	Tristeza
AU 17	“Mentalis”	Tristeza
AU 20	“Risorius”	Miedo
AU 24	“Orbicularis Oris”	Ira, Asco
AU 25	“Depressor Labii, or Relaxation of Mentalis or Orbicularis Oris	Sorpresa, Felicidad y Miedo
AU 26	“Masseter; Temporal and Internal Pterygoid Relaxed”	Sorpresa

Tabla 1 Significado de AUs y sus emociones [5]

2.2 Aplicaciones

El Reconocimiento de Emociones Faciales (FER) se ha incorporado en diversas aplicaciones reales, cada una con requerimientos específicos que influyen directamente en el diseño y evaluación de los modelos. Estas aplicaciones permiten identificar criterios clave como robustez, eficiencia computacional y explicabilidad, elementos que justifican la necesidad de estudios comparativos de arquitecturas.

En el ámbito educativo el FER puede utilizarse para detectar estados emocionales de estudiantes, puesto que las emociones presentan especial importancia al influir en procesos como la atención, la memoria o la resolución de problemas y su correspondiente identificación resulta esencial para el ambiente educativo y el aprendizaje[6].

En el sector de la seguridad, los sistemas FER apoyan la detección de comportamientos anómalos en espacios públicos o instalaciones sensibles. Aquí, los modelos deben ofrecer alta precisión y robustez frente a diversidad de personas, condiciones ambientales y expresiones parciales, con una latencia reducida para permitir respuestas rápidas [7].

En el sector del transporte[8] estos sistemas resultan relevantes para advertir el estrés, fatiga o distracciones, aportando información crítica para sistemas de asistencia dentro de vehículos.

En el sector de la salud los sistemas FER han demostrado su utilidad en salud mental, telemedicina y monitorización de pacientes. La detección automática de estados emocionales puede complementar la evaluación clínica, especialmente en entornos de atención remota, donde el terapeuta no tiene acceso directo al paciente[9].

Finalmente, estos sistemas toman especial importancia en la asistencia y el apoyo a grupos específicos con dificultades en el reconocimiento emocional [10] como pueden ser personas con discapacidad visual o Trastorno del Espectro Autista. Se facilita en tiempo real al usuario la identificación y comprensión de emociones faciales de otros individuos, lo que es esencial para cualquier interacción social.

En conjunto, estas aplicaciones muestran que el rendimiento de los modelos FER debe evaluarse considerando múltiples criterios. Esta variedad de requisitos técnicos indica que la elección de una arquitectura para FER no puede basarse únicamente en el rendimiento global, sino que deben considerarse factores adicionales como la eficiencia computacional, la robustez y la interpretabilidad. Este proyecto explora precisamente esa evaluación multidimensional, comparando distintas arquitecturas con el objetivo de analizar su comportamiento ante requisitos técnicos diversos.

2.3 Datasets

Para cualquier técnica de aprendizaje automático los conjuntos de datos sirven como repositorio de atributos esenciales pudiendo ser imágenes estáticas, videos o una combinación de ambos. En el contexto de este trabajo, nos centraremos en imágenes estáticas [11].

Las siguientes secciones describen varios conjuntos de datos estándar.

2.3.1 JAFFE

La base de datos de Expresiones Faciales Femeninas Japonesas (Japanese Female Facial Expression, JAFFE [12]) fue uno de los primeros datasets FER y se utilizó

ampliamente para validar métodos clásicos en condiciones controladas. Presenta 213 imágenes en blanco y negro con una resolución de 256x256, clasificadas según las seis emociones básicas clasificadas por Ekman (ira, asco, miedo, felicidad, tristeza, sorpresa)[2] con una etiqueta de neutra añadida. Los datos fueron posados por diez modelos japonesas. (Ver Figura 2)




Figura 2 Muestras de emociones en el dataset JAFFE

2.3.2 AffectNet

AffectNet[13] es un conjunto de datos a gran escala diseñado para el reconocimiento de emociones faciales en condiciones no controladas (Ver Figura 3). Contiene más de un millón de imágenes faciales recopiladas de Internet, de las cuales aproximadamente 400.000 están anotadas manualmente por únicamente tres sujetos y el resto fueron etiquetadas automáticamente con una incertidumbre de anotación del 35% [14]. Esta combinación de etiquetado poco fiable y anotación manual con un número reducido de revisores introduce un alto nivel de ruido en las etiquetas (*label noise*), comprometiendo la consistencia del conjunto de datos y la fiabilidad de los resultados obtenidos sobre él. Debido a su elevada variabilidad en poses, iluminación, expresiones parciales y oclusiones, AffectNet está siendo ampliamente utilizado para entrenar y evaluar modelos de aprendizaje profundo con alta capacidad de generalización en reconocimiento de emociones faciales, si bien sus limitaciones en cuanto a calidad de anotación deben tenerse en cuenta al interpretar los resultados reportados.



Figura 3 Ejemplos de imágenes etiquetadas del dataset AffectNet [13]

2.3.3 RAF_DB

RAF_DB (*Real-World Affective Faces Database*) [15], se presenta al igual de AffectNet como uno de los conjuntos de datos más relevantes de FER en entornos no controlados, proporcionando muestras muy variadas en poses, iluminación y expresiones (Ver Figura 4). El dataset completo cuenta con aproximadamente 30.000 muestras de rostros reales etiquetados por 40 sujetos de forma independiente con las seis emociones básicas clasificadas por Ekman (ira, asco, miedo, felicidad, tristeza, sorpresa)[2] y 12 emociones compuestas junto con información de etiquetas demográficas de género, edad y raza. A diferencia de otros dataset FER, el proceso de etiquetado de RAF-DB por 40 anotadores reduce el impacto del *label noise* y proporciona etiquetas de mayor fiabilidad para el entrenamiento y la evaluación de modelos.

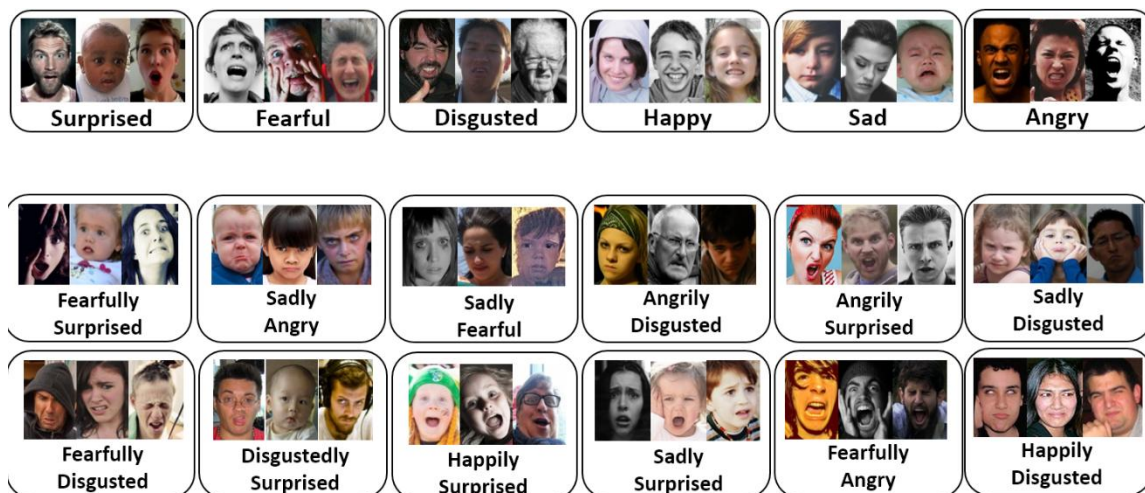


Figura 4 Muestras etiquetadas del dataset RAF-DB [15]

2.3.4 FER2013

Fer2013[16] es uno de los datasets más utilizados en FER. Compuesto por 35.887 imágenes en blanco y negro de 48x48, divididas en tres subconjuntos para entrenamiento, validación y test en una proporción 80x10x10, clasificadas según las siete emociones básicas (Ver Figura 5). Debido a su tamaño, diversidad y uso extensivo en la literatura, FER-2013 constituye un punto de referencia adecuado para la evaluación y comparación de distintos modelos de visión artificial aplicados al reconocimiento de emociones faciales, permitiendo analizar tanto el rendimiento como la capacidad de generalización de las arquitecturas evaluadas.



Figura 5 Ejemplos de imágenes del dataset FER2013 [17]

2.3.5 CK+

CK+ se convirtió en uno de los *benchmarks* clásicos para métodos basados en *Action Units* y visión artificial tradicional. Presenta 593 imágenes en blanco y negro de 123 personas de entre 18 y 50 años tomadas en un entorno controlado de laboratorio[18]. Está compuesto por secuencias de imágenes faciales capturadas en condiciones controladas, que representan la transición desde una expresión neutra hasta la expresión máxima de una emoción (Ver Figura 6). Debido a su alta calidad de anotación y a la ausencia de ruido ambiental, CK+ se emplea frecuentemente para analizar el comportamiento de modelos FER en condiciones ideales, aunque esto hace que no permita generalizar en entorno reales.



Figura 6 Ejemplos de imágenes de dataset CK+ [19]

La siguiente Tabla 2 presenta una comparativa de los datasets mencionados en concepto de resolución, tamaño, características y tipo de recolección.

Dataset	Características	Nº Imágenes	Resolución	Entorno controlado
JAFPE	Imágenes en blanco y negro de 256x256 de modelos japonesas con expresiones posadas	213	256x256	SÍ
FER2013	Imágenes en blanco y negro con resolución de 48x48	35.887	48x48	NO
RAF_DB	Imágenes color, con alta variabilidad en resolución, poses, iluminación y expresiones.	30.000	Variable	NO
AffectNet	Imágenes color, con alta variabilidad en resolución, poses, iluminación y expresiones.	1.000.000	Variable	NO

CK+	Secuencias e imágenes faciales en escala de grises, con resolución variable	593	48x48	Sí
------------	---	-----	-------	----

Tabla 2 Comparativa de los datasets FER analizados

2.4 Enfoques Clásicos

En las primeras etapas del desarrollo de sistemas FER, los enfoques se basaban principalmente en técnicas de visión artificial clásica basada en la extracción manual de características y su clasificación[20].

Entre los más utilizados se encuentran LBP (Local Binary Patterns) y HOG (Histogram of Oriented Gradients), mientras que los clasificadores más comunes incluyen SVM (Support Vector Machines), RandomForests y KNN (k-Nearest Neighbors)[21][22]. Aunque estos métodos ofrecían resultados aceptables, eran poco robustos y su rendimiento disminuía con cambios de iluminación o resolución.

2.4.1 Extracción manual de características

Las aproximaciones de visión artificial clásica para el FER se basan en la extracción manual de características[23] con herramientas como LBP (Local Binary Patterns), HOG (Histogram Oriented Gradient) o filtros Gabor, combinados con un clasificador tradicional adicional como SVM (Support Vector Machine) o RandomForest. Aunque en unas primeras etapas de estudios sobre el reconocimiento facial de emociones estas técnicas tuvieron buenos resultados, su rendimiento se ve limitado en condiciones no controladas de variación de iluminación y/o pose.

Existen dos enfoques comunes para la extracción manual de características faciales[24], métodos basados en rasgos geométricos y métodos basados en la apariencia[25]. Los rasgos geométricos presentan la forma y la ubicación de los componentes faciales, que se extraen para formar un vector de características que representa la geometría del rostro. Diversos estudios han analizado el rendimiento de los métodos basados en rasgos geométricos y basados en la apariencia en reconocimiento de emociones faciales. Si bien los enfoques geométricos pueden ofrecer un rendimiento competitivo en entornos controlados, su dependencia de una detección precisa de

rasgos faciales limita su robustez en condiciones no controladas. Por su parte, los métodos basados en la apariencia, como LBP, HOG o filtros de Gabor, han demostrado un comportamiento más estable en escenarios reales, lo que ha motivado su uso extendido en sistemas clásicos de FER.[26].

2.4.1.1 Local Binary Patterns (LBP)

El operador Local Binary Patterns (LBP)[27] es un descriptor de textura que codifica patrones locales de intensidad en una imagen. Su bajo coste computacional y robustez frente a cambios de iluminación motivaron su amplia adopción en sistemas FER clásicos. Para cada píxel, se considera un umbral de 3×3 y se compara el valor de intensidad de los píxeles vecinos con el del píxel central. Cada comparación se binariza asignando un valor de 1 si el píxel vecino es mayor o igual que el central, y 0 en caso contrario. Los valores binarios obtenidos se concatenan para formar un número binario de 8 bits, que se convierte en una etiqueta decimal entre 0 y 255 como se ve reflejado en la Figura 7. A partir de estas etiquetas se construye un histograma de 256 binarios, que actúa como descriptor de textura de la imagen. Este descriptor captura información local relevante para el reconocimiento de expresiones faciales, como bordes, esquinas y patrones de arrugas. [24]




Figura 7 Proceso de codificación en LBP [30]

Finalmente, el vector de características obtenido se utiliza como entrada a un clasificador supervisado como SVM.

2.4.1.2 Histogram Oriented Gradient (HOG)

Histogram of Oriented Gradients (HOG)[28] es un descriptor de características basado en la distribución local de orientaciones de gradiente. Mientras que LBP captura patrones locales de textura, HOG enfatiza la información geométrica asociada a bordes

y contornos faciales. Este método aplicado al reconocimiento facial captura información estructural relevante del rostro, como contornos y bordes, dividiendo la imagen en celdas locales y calculando histogramas de orientación que posteriormente son normalizados por bloques. El vector de características resultante se emplea como entrada a un clasificador. HOG resulta ampliamente utilizado en sistemas clásicos de reconocimiento de expresiones faciales debido a su robustez frente a variaciones moderadas de iluminación y su capacidad para representar la forma facial [29].

2.4.1.3 Filtros Gabor

Estos sistemas de reconocimiento se basan en la utilización de bancos de filtros Gabor para representar imágenes faciales mediante la convolución de la imagen con múltiples filtros parametrizados por varias escalas y orientaciones [30]. De esta forma las imágenes son proyectadas a un espacio de características en respuesta a los filtros aplicados (Figura 8). Estas respuestas son posteriormente introducidas en un clasificador supervisado.




Figura 8 Proceso de aplicación de filtros Gabor [30]

Los resultados presentados [30] demuestran un rendimiento competitivo en comparación con otras aproximaciones clásicas basadas en la extracción de características. Sin embargo, a pesar de su rendimiento, el uso de filtros Gabor requiere

diseñar manualmente los filtros y conlleva un gran coste computacional y de memoria, lo que ha provocado que posteriores investigaciones se basen en aproximaciones más CNN más flexibles y escalables.

2.4.2 Clasificadores tradicionales

2.4.2.1 Support Vector Machine (SVM)

Support Vector Machines (SVM) es un modelo de aprendizaje supervisado para problemas de clasificación y regresión. SVM separa los datos en distintas clases utilizando un algoritmo que analiza los datos y los transforma a un espacio con más dimensiones donde datos que antes eran difíciles de separar pueden organizarse de forma más clara.

Finalmente, SVM construye un hiperplano que divide las clases (Ver Figura 9). El objetivo es separar los datos de la forma más eficiente posible, por ello, se busca el hiperplano que deje mayor margen entre las clases, lo que ayuda a que el modelo generalice mejor cuando se enfrenta a nuevos datos. Los puntos de cada clase más cercanos al hiperplano son los vectores de soporte (Support Vector) y definen la posición final del hiperplano.[31]

Se caracteriza por ser un método fiable y eficaz, respaldado por una base estadística sólida, lo que las hace especialmente útiles cuando se trabaja con datos complejos o de alta dimensión.[32]




Figura 9 División de clases SVM mediante hiperplano

2.4.2.2 Random Forest

Random Forest[33] es otro modelo de aprendizaje para problemas de clasificación y regresión, que construye varios árboles de decisión donde cada uno entrena de forma independiente utilizando una parte aleatoria de los datos de entrenamiento y un conjunto aleatorio de las características disponibles. Esto hace que los árboles sean diferentes, haciendo que cada uno aprenda patrones ligeramente distintos. Una vez entrenados todos los árboles, el modelo combina sus resultados para tomar una decisión final. En clasificación, la clase más votada es la que se asigna, en regresión, se calcula el promedio de las predicciones.

Este modelo es capaz de capturar relaciones complejas entre las variables y manejar grandes volúmenes de datos sin transformaciones complicadas. Además, es menos sensible al ruido y ofrece un buen equilibrio entre precisión y facilidad de uso.

2.5 Arquitecturas profundas

Con el auge del aprendizaje profundo, y en particular de las redes neuronales convolucionales (CNN), el reconocimiento de emociones faciales experimentó un avance. Inicialmente, las CNN se aplicaron a tareas de segmentación, detección de objetos y el reconocimiento de imágenes, demostrando gran capacidad de aprendizaje[34]. Posteriormente, estas arquitecturas comenzaron a aplicarse al FER, logrando superar en rendimiento a los métodos tradicionales. A comienzos de este siglo, diversos artículos [35][36], probaron que las CNN eran más robustas frente a cambios como la localización del rostro o variaciones de escala, rotación o traslación.

En los últimos años, se ha producido un crecimiento notable en el uso de arquitecturas profundas cada vez más sofisticadas, así como en el empleo de modelos preentrenados y estrategias de *transfer learning*, lo que ha permitido mejorar el rendimiento incluso en escenarios con conjuntos de datos limitados, utilizando modelos preentrenados con grandes conjuntos de datos generales como ImageNet que se reentrenan con conjuntos de datos específicos de FER, mejorando así la capacidad de convergencia y generalización, reduciendo la necesidad de grandes cantidades de datos etiquetados.

Entre las arquitecturas más relevantes para esta tarea destacan ResNet y EfficientNet, que representan dos enfoques distintos para mejorar la capacidad de representación y la eficiencia computacional en redes profundas. Los resultados más recientes indican que los enfoques basados en aprendizaje profundo ofrecen mayor precisión, robustez y capacidad de generalización en comparación con los métodos convencionales [20] [37].

A pesar de los avances logrados con respecto al rendimiento de los modelos, estos aun presentan desafíos como la robustez general ante condiciones no controladas, la interpretabilidad y la eficiencia computacional, que serán una de las cuestiones de estudio en este trabajo.

2.5.1 ResNet

ResNet (Residual Network) [38], supuso un avance en el diseño de las CNNs profundas al introducir el concepto de las conexiones residuales (skip connections) que disminuyen el problema del desvanecimiento de gradiente. Cuando tratamos con redes muy profundas los gradientes, los gradientes que se propagan hacia atrás durante el entrenamiento tienden a reducirse de forma exponencial a medida que se profundiza en la red, a este fenómeno se le denomina desvanecimiento de gradiente. Para resolver este fenómeno, las conexiones residuales permiten que la señal viaje directamente desde la entrada de un bloque hasta su salida, de forma que cada bloque aprenda únicamente la diferencia de residual con respecto a la entrada, en lugar de su transformación completa, estabilizando el entrenamiento y permitiendo entrenar redes más profundas.

La arquitectura organiza sus capas como bloques residuales con configuración de cuello de botella (secuencias convoluciones 1x1, 3x3, 1x1), donde las convoluciones 1x1 reducen la dimensionalidad, disminuyendo el coste sin renunciar a la capacidad de representación; las convoluciones 3x3 son la principal capa de extracción de características espaciales; y finalmente la convolución 1x1 restaura la dimensionalidad original. Además, se agrega BatchNormalization tras cada capa convolucional, estabilizando las activaciones y acelerando la convergencia. Dentro de ResNet existe

diferentes configuraciones en función del número de bloques apilados, incluyendo variantes desde ResNet18 hasta ResNet152.

La profundidad de ResNet, combinada con sus conexiones residuales, permite modelar relaciones espaciales complejas entre distintas regiones faciales sin sufrir los problemas de optimización característicos de CNNs profundas convencionales. Esto resulta especialmente relevante en FER, donde diferencias emocionales sutiles dependen de variaciones locales muy concretas en ojos, cejas, nariz y boca [39]. La profundidad permitida por ResNet junto con sus conexiones residuales permite capturar características faciales distintivas sin problemas de optimización, lo que resulta relevante para distinguir emociones anatómicamente similares como lo son la sorpresa y el miedo.

2.5.2 EfficientNet

EfficientNet [40] supuso un avance en el diseño de CNN por introducir el *compound scaling*, un método que escala a la vez la profundidad, anchura y resolución. Previamente, las redes clásicas escalaban aumentando un solo factor (más capas, más filtros o mayor resolución), pero EfficientNet distribuye el incremento de capacidad entre estos tres elementos mediante un coeficiente de escalado compuesto, lo que permite una mayor eficiencia en cuanto a recursos computacionales

La arquitectura utiliza bloques MBConv (*Mobile Inverted Bottleneck Convolution*) que emplean dos técnicas relevantes para la eficiencia.

1. Aplica convoluciones *depthwise* que procesa cada canal de forma independiente y después combinan la información mediante convoluciones 1×1 . Así se reduce el número de parámetros y operaciones manteniendo la capacidad representacional.
2. Integra módulos Squeeze-and-Excitation, un mecanismo que recalibra la importancia de cada mapa de características mediante tres pasos, primero, una fase de *squeeze* que resume cada canal mediante Global Average Pooling. Después, una fase de *excitation* que, mediante dos capas completamente conectadas con activación sigmoide, aprende pesos de importancia para cada canal. Finalmente, una recalibración que multiplica cada canal por su peso aprendido (mecanismo de atención de canales), permitiendo detectar características relevantes y reducir el ruido con un coste computacional bajo.

Entre sus principales ventajas se encuentran la alta eficiencia (mejor precisión con menos parámetros que ResNet o VGG), la escalabilidad controlada mediante variantes B0-B7 adaptadas a diferentes recursos computacionales, y su efectividad para transfer learning. Como desventajas presenta cierta complejidad en la implementación de los bloques MBConv y, por tanto, entrenamiento más lento que otras arquitecturas más simples.

Las variantes EfficientNet-B0 a EfficientNet-B7 se diferencian por la aplicación de diferentes grados de compound scaling sobre la arquitectura base, aumentando la profundidad, la anchura y la resolución de entrada, lo que permite adaptar el modelo a distintos niveles de recursos computacionales.

En FER, EfficientNet es particularmente relevante porque las convoluciones depthwise capturan eficientemente características locales faciales como bordes de ojos, boca y cejas, mientras que los módulos Squeeze-and-Excitation priorizan zonas relevantes para cada emoción.

2.5.3 Transformers

Los transformers surgieron en el ámbito del Procesamiento del Lenguaje Natural (NLP) con la finalidad de procesar texto y su éxito ha motivado su adaptación a otros campos. De esta forma, aparecen los Vision Transformers (ViT), que representan una adaptación de la arquitectura original de los transformers empleados en NLP al ámbito de la visión por computador[41].

Los ViT consisten en un modelo basado en atención, sin convoluciones, donde se divide la imagen en parches de tamaño fijo y se trata cada parche como se trataría un token en un transformer propio de NLP, se proyecta linealmente en un embedding vectorial, se agregan embedding posicionales para conservar la posición espacial de cada parche creado y finalmente se alimenta un transformer encoder con la secuencia. Este encoder está compuesto por capas de atención multi-cabeza que permiten a cada parche atender a todos los demás simultáneamente, captando relaciones globales, y bloques MLP (Multi-Layer Perceptron), que procesan cada parche de forma independiente. Ambos elementos están conectados por skip connections y normalizaciones. Podemos ver esta idea reflejada en la siguiente Figura 10.




Figura 10 Arquitectura general de ViT [42]

Los Vision Transformers presentan diferentes variantes en función del tamaño del modelo (ViT/Tiny, ViT/Small, ViT/Base, ViT/Large...), así como variaciones en el tamaño del patch (patch 8, 16 o 32).

En FER los ViT resultan relevantes por su capacidad para aprender patrones locales y globales en el rostro al segmentar la imagen en parches. Además, la atención multi-cabeza facilita la identificación de regiones faciales más relevantes para cada expresión, lo que abre la posibilidad de aplicar técnicas de explicabilidad visual basadas en los pesos de atención.

Una desventaja de los ViT es su necesidad de grandes cantidades de datos cuando se entrenan desde cero[43]. Esto se debe a que, a diferencia de las CNNs que incorporan un sesgo inductivo a través de la conectividad local y la compartición de pesos en los filtros convolucionales, los ViT no lo tienen, como modelo basado en atención, los ViT aprenden explícitamente propiedades como la localidad espacial y la invariancia a traslaciones[44], lo que requiere conjuntos de datos más extensos. Sin embargo, el transfer learning con pesos preentrenados en ImageNet alivia este problema al aprovechar características generales aprendidas en conjuntos de datos extensos, permitiendo adaptar el modelo a tareas específicas como FER con recursos limitados.

Capítulo 3 - Revisión de la tecnología

3.1 Redes Neuronales Convolucionales (CNNs)

Entrando en detalle, las CNN están formadas por tres tipos principales de capas: capas convolucionales, capas de pooling y capas densas. Cada una cumple una función específica dentro del proceso de aprendizaje[19].

Las **capas convolucionales** poseen un conjunto de filtros o kernels que recorren toda la imagen realizando operaciones de convolución, cada filtro detecta patrones concretos como bordes o texturas generando distintos mapas de activación que representan dichos patrones en cada región de la imagen. A medida que se profundiza en la red, estos patrones se vuelven más complejos y, por tanto, un mayor número de capas convolucionales permitirá aprender representaciones más complejas. El uso de estas capas trae varios beneficios como la conectividad local que permite aprender correlaciones entre píxeles vecinos; también aportan cierta robustez a las traslaciones ya que un patrón no va a depender de su posición exacta.

La **capa de pooling** sigue a la capa convolucional y se utiliza para reducir el tamaño espacial de los mapas de activación y el coste computacional.

Finalmente, la **capa densa** suele incluirse al final de la red para garantizar que todas las neuronas de la capa estén completamente conectadas a las activaciones de la capa anterior y para permitir que los mapas de características 2D se conviertan en mapas 1D para una posterior representación de características y clasificación.

La Tabla 3 muestra las características de los modelos CNN que comúnmente se aplican en FER. Estos modelos difieren en las siguientes características:

- 1. Número de capas:** Indica el número de capas, considerando las capas convolucionales y las densas (convolucionales + densas). Un mayor número de capas permitirá aprender patrones más complejos. De esta forma, ResNet es una arquitectura mucho más profunda que las demás, capaz de identificar patrones más complejos y manejar mejor variaciones sutiles en las expresiones faciales. Sin embargo, una mayor profundidad también implica mayor consumo de memoria y

mayor tiempo de entrenamiento, por lo que las arquitecturas muy profundas requieren optimizaciones adicionales.

2. **Tamaño de Kernel:** El *kernel* define el tamaño del filtro aplicado. AlexNet utiliza *kernels* grandes de (11, 5 y 3) adecuados para capturar patrones de distintas escalas desde las primeras capas. Mientras que por ejemplo VGGNet emplea *kernels* más pequeños de tamaño 3 lo que permite extraer características de forma más precisa. Finalmente, GoogleNet y ResNet combinan distintos tamaños de *kernel* (7, 1, 3 y 5) para capturar información a diferentes escalas dentro de la misma capa, lo que mejora la capacidad de la red para reconocer patrones complejos, esto aumenta el coste computacional y de memoria, pero permite un término medio entre eficiencia y capacidad de representación.
3. **Dropout:** Esta es una técnica de regularización que consiste en desactivar aleatoriamente un cierto % de neuronas durante el entrenamiento. Este proceso permite reducir el *overfitting* y mejorar la capacidad de generalización al obligar al modelo a entrenar con pérdidas aleatorias de información.
4. **Inception:** Estos bloques se encuentran presentes únicamente en GoogleNet y permiten realizar convoluciones de distintos tamaños en paralelo dentro de la misma capa. De esta forma, se mejora la extracción de características de mayor y menor complejidad sin tener que agregar más capas, mejorando así la capacidad de generalización sin tener que aumentar excesivamente la complejidad computacional.
5. **Batch Normalization:** Este es un método de normalización presente únicamente en ResNet que normaliza los mapas de activación de cada capa estabilizando la distribución de datos y permitiendo una tasa de aprendizaje (*Lr*, *Learning rate*) superior, acelerando así la convergencia y mejorando la eficiencia del entrenamiento.

Modelo	AlexNet	VGG	GoogLeNet	ResNet
Nº Capas	5 + 3	13/16 + 3	21 + 1	151 + 1
Kernel	11, 5, 3	3	7, 1, 3, 5	7, 1, 3, 5
Dropout	SÍ	SÍ	SÍ	SÍ
Inception	NO	NO	SÍ	NO
Batch Normalization	NO	NO	NO	SÍ

Tabla 3 Comparativa de arquitecturas CNNs clásicas utilizadas en visión artificial [19]

Con el avance del aprendizaje profundo se observaron ciertas limitaciones en las arquitecturas clásicas, especialmente en concepto de escalabilidad y eficiencia computacional. En respuesta a ello, aparecen nuevas arquitecturas como las mencionadas en los siguientes apartados.

3.2 Transfer Learning

El Transfer Learning[45] es una técnica en aprendizaje profundo que aprovecha el conocimiento aprendido por los modelos para mejorar el rendimiento en una tarea nueva. El proceso parte de un modelo preentrenado con un conjunto extenso de datos, en visión artificial suele ser ImageNet[46] que contiene millones de imágenes de diferentes categorías. Este preentrenamiento permite que el modelo aprenda representaciones visuales genéricas de bajo nivel como bordes, texturas y formas y características de nivel intermedio transferibles a otros dominios. Posteriormente estas representaciones se adaptan a la tarea específica mediante dos estrategias principales.

1. **Feature Extraction.** Se congelan los pesos de las capas convolucionales preentrenadas y únicamente se entrenan las capas densas finales con los datos de la tarea nueva específica. De esta forma, se aprovechan las características generales aprendidas para entrenar las nuevas capas sin modificar los pesos obtenidos del preentrenamiento.

2. **Fine-Tuning.** Se descongelan parcial o totalmente las capas preentrenadas y se reentrenan con una tasa de aprendizaje (η) baja. Así, se adaptan las características preentrenadas a las específicas de la tarea nueva.

En el contexto del FER, los conjuntos de datos disponibles suelen ser de un tamaño pequeño o mediano, por lo que estrategias como el Transfer Learning resultan esenciales para mejorar la capacidad de generalización de los modelos, permitiendo entrenar arquitecturas profundas sin necesidad de grandes cantidades de datos.

3.3 Técnicas de Balanceo

En el aprendizaje automático, es frecuente que los conjuntos de datos no presenten una distribución uniforme entre sus clases, mostrando algunas un número de muestras mayor que otras. Este fenómeno se conoce como desbalanceo y supone uno de los problemas más habituales al trabajar con datos reales.

En caso de querer solventar esta situación modificando el contenido del dataset, existen diversas técnicas. Un desbalance puede solventarse por tres estrategias que podrían combinarse entre ellas.

1. **Undersampling:** Consiste en eliminar muestras de las clases predominantes, hasta igualar su tamaño con las clases minoritarias. Aunque esta técnica reduce el sesgo hacia las clases mayoritarias, supone una pérdida significativa de información, lo que en una tarea compleja como el reconocimiento facial de emociones resulta problemático.
2. **Oversampling:** Consiste en incrementar el número de muestras de las clases minoritarias hasta alcanzar una distribución equilibrada. Esta estrategia puede introducir redundancia y aumentar el riesgo de sobreajuste, especialmente cuando se basa en replicación directa de muestras. En el contexto de este proyecto, la generación manual de datos adicionales no resulta viable, y la combinación con otros datasets podría afectar negativamente a la capacidad de generalización al no garantizarse condiciones homogéneas.
3. **Data Augmentation:** Consiste en introducir nuevos casos mediante la modificación geométricas (cambios de resolución, brillo, rotaciones) de casos existentes. Esta

estrategia puede incrementar el riesgo de sobreajuste y no garantiza una corrección completa del sesgo estadístico inherente a la distribución original.

Es posible, sin embargo, entrenar modelos de aprendizaje profundo con datasets desbalanceados mediante métricas específicas para desbalanceo como F1-Macro o Balanced Accuracy o mediante el uso de `class_weight="balanced"`, que introduce una ponderación inversamente proporcional a la frecuencia de cada clase en la función de pérdida, compensando parcialmente el efecto del desbalance sin alterar la distribución original de los datos.

3.4 Robustez

La robustez resulta ser una propiedad muy relevante en el contexto de los modelos de aprendizaje profundo que se define como la capacidad de un modelo para mantener su rendimiento cuando las condiciones de las imágenes de entrada varían con respecto a las observadas durante el entrenamiento. Esta propiedad es muy importante para garantizar que los modelos han aprendido a generalizar adecuadamente en escenarios realistas, donde las condiciones de captura no están controladas.

En FER, la robustez resulta especialmente relevante debido a la cantidad de factores que pueden afectar a la calidad y características de la imagen de entrada, que pueden variar en su iluminación, posición, resolución, características demográficas... Un modelo robusto debe ser capaz de reconocer las emociones de forma consistente independientemente de estos cambios, garantizando su rendimiento en condiciones no controladas.

Existen distintas características de robustez que se pueden evaluar:

1. **Robustez ante variaciones geométricas:** Representa la capacidad de un modelo para mantener su rendimiento ante cambios en la posición de la cara (rotaciones, inclinaciones...), traslaciones espaciales de la cara dentro de la imagen o cambios de escala. Estos cambios son muy comunes en aplicaciones reales donde la captura no sigue patrones estandarizados.

- 2. Robustez ante variaciones en la iluminación:** Representa la capacidad de un modelo para mantener su rendimiento ante cambios en la iluminación, brillo, contraste y distribución de sombras. La iluminación resulta un aspecto crítico ya que su variabilidad es inevitable.
- 3. Robustez ante degradación de la calidad de la imagen:** Representa la capacidad del modelo para mantener su rendimiento ante ruido, desenfoque o pérdida de resolución. Estos elementos son comunes en entornos reales donde las imágenes proceden de sensores con distinta calidad o han sido comprimidas para su almacenamiento.
- 4. Robustez ante variaciones demográficas:** Representa la capacidad de un modelo para mantener su rendimiento independientemente de las características demográficas de las personas, como edad, etnia o género. Esta robustez resulta especialmente importante para evitar sesgos en los modelos.

Por tanto, la evaluación de la robustez resulta importante para garantizar que los modelos sean funcionales en escenarios realistas, más allá de conjuntos de datos de prueba.

3.5 Explicabilidad

La explicabilidad o interpretabilidad, se define como el grado en que un ser humano puede comprender la causa de una decisión[47]. En concreto, este concepto se aplica a la IA como métodos que nos permiten obtener una justificación general del funcionamiento de un modelo y qué elementos lo han llevado a dar un determinado resultado.

Cuanto más interpretable sea un modelo de aprendizaje automático, más fácil será comprender por qué se tomaron ciertas decisiones o predicciones. Es importante destacar en el contexto de la explicabilidad que, aunque modelos más complejos presentan mejor rendimiento y precisión, también resultan menos explicables. En la Figura 11, podemos ver la relación entre la explicabilidad de un modelo y su accuracy junto con la mejora en interpretabilidad que supone la aplicación de modelos de explicabilidad.




Figura 11 Relación Explicabilidad – Accuracy [48]

Tipos de explicabilidad

Dentro de los métodos de explicabilidad encontramos métodos globales basados en atributos que justifican cómo funciona el modelo en general y qué patrones se han aprendido a partir del conjunto de datos. Nos permite obtener información sobre qué características generales son relevantes para el modelo y si existen sesgos o dependencias no deseadas, además de aportar información sobre cómo cambia el comportamiento del modelo entre distintas clases.

Los métodos locales basados en atributos explican una predicción concreta para una imagen específica, nos permiten validar predicciones individuales, detectando casos críticos y generando confianza en el usuario final.

Existen a su vez, métodos explicables basados en instancias que explican una predicción señalando ejemplos concretos que han influido en la decisión. De esta forma se justifican decisiones con ejemplos reales, lo que genera una mayor confianza en el usuario final.

Los métodos de explicabilidad que se implementen dependerán del caso en particular que se esté tratando, su criticidad y el usuario objetivo de dicha explicabilidad. Si, por ejemplo, tratamos el caso de un detector de cáncer por imagen, quien desarrolle el sistema estará probablemente interesado en un método de explicabilidad global que le permita depurar el sistema, mejorarlo y cribar sesgos. Sin embargo, el médico que utilizase dicho detector estaría interesado en un método de

explicabilidad local basado en instancias o en atributos que le justificase el resultado de forma que pueda discernir si la decisión es correcta o no.

La importancia de la explicabilidad surge especialmente cuando, para ciertos problemas, saber cuál es la predicción no es suficiente, sino que es necesario saber el porqué. Esto puede ser por diferentes razones, medidas de seguridad, detección de riesgos, una necesidad de aumento de la confianza de la sociedad en estos sistemas o depuración y auditoria.

Técnicas de explicabilidad en redes convolucionales

Entre las técnicas de explicabilidad más empleadas en redes neuronales convolucionales se encuentra Grad-CAM[49] (Gradient-weighted Class Activation Mapping). Este método permite generar mapas de calor que destacan las regiones de la imagen que más contribuyen a la predicción de una clase concreta (Figura 12), utilizando la información de los gradientes en las capas convolucionales finales. De esta forma, Grad-CAM permite analizar si el modelo se centra en regiones facialmente relevantes, como la boca, los ojos o las cejas, coherentes con el conocimiento humano sobre la expresión de emociones. El uso de estos mapas resulta especialmente útil para analizar errores de clasificación, ya que permite identificar situaciones en las que el modelo se apoya en elementos no relevantes. Este tipo de análisis permite validar si el modelo ha aprendido patrones consistentes.




Figura 12 Mapa Grad-CAM para una predicción de la emoción sorpresa

Técnicas de explicabilidad en Transformers

En el caso particular de los Transformers (ViT), estos presentan una arquitectura completamente diferente de las redes convolucionales, basándose en mecanismos de

atención en lugar de filtros convolucionales[50], como se explica en el apartado 2.5.3. Esta diferencia requiere una técnica de explicabilidad específica.

Existe la posibilidad de adaptar Grad-CAM aplicándolo a las capas finales del transformer[51], pero esta aproximación ignoraría los mapas de atención generados de forma interna por el transformer que nos indican qué regiones de la imagen el modelo ha considerado relevantes en cada capa.

Attention Rollout [52] es otra técnica relevante a tener en cuenta ya que propaga los mapas de atención a través de todas las capas del transformer, acumulando los pesos de atención de forma jerárquica para generar una visualización que muestra qué parches de la imagen contribuyen más a la predicción final, aprovechando la estructura interna del transformer.

Prototipos, críticas y representación en el espacio.

En concreto, tres conceptos de explicabilidad resultan relevantes, prototipo, crítica y la representación en el espacio, para visualizar y analizar cómo cada modelo organiza las instancias en el espacio a nivel interno, permitiendo una explicabilidad a nivel global. Para ello, se emplean técnicas como t-SNE[53] (*t-Distributed Stochastic Neighbor Embedding*). Esta es una técnica de reducción de dimensionalidad que proyecta los embeddings de alta dimensionalidad en un espacio de dos dimensiones, conservando las similitudes entre instancias, permitiendo identificar patrones de agrupación, solapamiento de clases y anomalías en la distribución de características aprendidas, permitiendo así un análisis de explicabilidad global.

Los **prototipos** son instancias que representan bien una clase, aquellos que el modelo asocia de forma más clara a una categoría, permitiendo entender. Representan los ejemplos cercanos a regiones de alta densidad de probabilidad de cada clase. (Figura 13)

Las **críticas** son aquellas instancias que, aunque pertenecen a una clase no están bien representadas por los prototipos, están situadas en regiones de baja densidad o en zonas donde las clases se solapan. Son casos atípicos. Las críticas resultan muy relevantes en explicabilidad al revelar las limitaciones del modelo o del dataset, permitiendo detectar sesgos o fronteras de decisión ambiguas. (Figura 13)

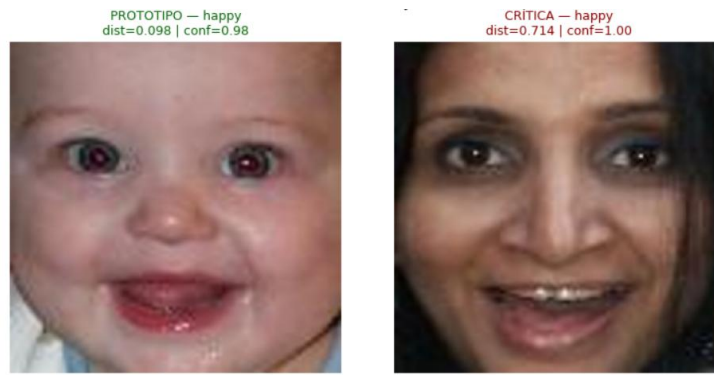


Figura 13 Representación de prototipos y críticas, ejemplo clase Happy

Capítulo 4 - Metodología de investigación

4.1 Selección del dataset

Para la selección del dataset y en base al análisis de los principales datasets de FER realizado en el apartado 2.3, se tuvieron en cuenta diversos aspectos. Se consideró especialmente decisivo que el dataset reflejase la realidad de forma fiel de forma que se pueda analizar qué comportamiento tendrían los modelos en casos de uso realistas, por lo que datasets obtenidos en entornos controlados con modelos como JAFFE o CK+ así como aquellos con imágenes en blanco y negro o con baja resolución como FER2013.

De esta forma, la decisión principal quedó entre AffectNet y RAF-DB, ambos dos de los datasets más relevantes de FER en entornos no controlados [14].

En concreto, AffectNet cuenta con cerca de 1.000.000 imágenes, donde cerca de la mitad fueron etiquetadas de forma manual por entre 1 y 3 personas y el resto fueron etiquetadas de forma automática. Algunos estudios han realizado tareas de revisión y reetiquetado de AffectNet, en concreto en Kim et al. 2023 [54], se realizó una prueba donde 13 participantes volvieron a etiquetar un subconjunto de AffectNet, resultando en que únicamente el 13% de los votos mantuvo la misma etiqueta.

Teniendo en cuenta todo lo anterior, para el entrenamiento de los modelos se utiliza el dataset RAF_DB por ser el que mejor representa condiciones reales de uso. A diferencia de otros datasets estudiados en el apartado 2.3, RAF_DB cuenta con imágenes a color tomadas en entornos no controlados con variaciones de poses y resolución. Esta diversidad lo convierte en un dataset apropiado para evaluar la capacidad de generalización de los modelos.

Aunque este dataset presenta una menor cantidad de muestras que otros de los estudiados, las muestras de RAF_DB fueron etiquetadas y validadas por más de 40 sujetos lo que aporta una confianza que carecen otros datasets como AffectNet donde sus muestras fueron etiquetadas por únicamente tres individuos y presenta una demostrada discrepancia[54].

Finalmente, es importante tener en cuenta que, para la elaboración de las pruebas y a pesar de haberlo solicitado, no se obtuvo respuesta por parte de equipo investigador encargado y no se logró obtener el dataset completo de RAF-DB por lo que se trabajará con un subconjunto extraído de *kaggle*¹, formado por aproximadamente 15.000 muestras etiquetadas.

Este subconjunto presenta la distribución reflejada en la Figura 14. Sin acceso al dataset original, no es posible afirmar que este subconjunto sea representativo del original en cuestión de distribución de clases. Por lo tanto, las conclusiones sobre el rendimiento de los modelos son válidas para este subconjunto específico, pero podrían variar al usar el dataset completo. Las comparaciones con otras investigaciones deben interpretarse considerando esta diferencia en datos de entrenamiento.




Figura 14 Distribución del dataset RAF-DB

4.2 Selección de modelos

La selección de los modelos realizada en este trabajo tiene como objetivo la creación de un estudio comparativo que permita analizar distintas aproximaciones al reconocimiento facial de emociones. En concreto, el objetivo es aislar la arquitectura

¹ <https://www.kaggle.com/datasets/shuvoalok/raf-db-dataset>

como variable independiente para evaluar su impacto en el rendimiento, eficiencia y comportamiento del modelo en la clasificación de emociones. Para ello, se han seleccionado modelos que cubran tres niveles de complejidad, por un lado, métodos clásicos de visión artificial basados en la extracción de características; arquitecturas profundas convolucionales clásicas y modernas y modelos basados en la atención.

En primer lugar, se incluye un **baseline** basado en la extracción manual de características mediante **HOG** y su posterior clasificación con **SVM**. Este enfoque se ha seleccionado en base a la investigación realizada en el apartado 2.4.1 y tiene como finalidad establecer un punto de referencia que contextualice la mejora aportada por los modelos de aprendizaje profundo. Además, ha sido escogido entre otras aproximaciones de extracción de características por su bajo coste computacional y sus resultados competitivos dentro de su categoría como se expone en el apartado 2.4.1.

En segundo lugar, tras el análisis realizado en el apartado 2.5 se incorporan arquitecturas profundas convolucionales. Concretamente, se emplean ResNet y EfficientNet, seleccionadas por los siguientes motivos.

ResNet, analizado en el apartado 2.5, introduce conexiones residuales que permiten entrenar redes mucho más profundas mitigando el problema del desvanecimiento del gradiente. Esta arquitectura representa una evolución estructural clave dentro de las CNN y resulta adecuada para analizar si el aumento de profundidad y capacidad de aprendizaje mejora el rendimiento en reconocimiento de emociones faciales en condiciones no controladas como las presentes en el dataset escogido.

EfficientNet, tras el análisis realizado en el apartado 2.5.2, se selecciona por su estrategia de escalado compuesto, que optimiza simultáneamente profundidad, anchura y resolución, permitiendo obtener modelos con alto rendimiento y menor número de parámetros. Su inclusión permite analizar si los modelos optimizados estructuralmente ofrecen ventajas en entornos con recursos limitados, aspecto relevante en aplicaciones reales.

Finalmente, se incorpora un modelo basado en mecanismos de atención, tras el análisis planteado en el apartado 2.5.3. **Vision Transformer** (ViT) representa un cambio de paradigma respecto a las CNN tradicionales, al modelar relaciones mediante

mecanismos de atención en lugar de convoluciones. Su inclusión permite analizar si la capacidad de capturar relaciones en la imagen aporta mejoras en la identificación de patrones emocionales faciales, así como estudiar cómo el modelo asigna atención a diferentes regiones faciales, permitiendo investigar patrones sobre su proceso de toma de decisiones.

Para cada arquitectura seleccionada se elige una variante específica, ResNet50, EfficientNet-B3 y ViT/B-16. Esta selección tiene como finalidad elegir dentro de cada familia de arquitecturas la variante que represente un equilibrio entre capacidad de modelado y eficiencia computacional.

4.3 Pipeline

4.3.1 Tratamiento del Dataset

Como se menciona en el apartado 4.1, el dataset escogido para el desarrollo de las pruebas es un subconjunto de RAF_DB extraído de Kaggle. Este dataset ya se encuentra dividido en Train y Test en una proporción 80/20. Se mantiene esta distribución para Test y se subdivide Train para obtener un conjunto de validación en proporción 80/20. El conjunto de validación resultará necesario para la selección de hiperparámetros y EarlyStopping durante el entrenamiento con las estrategias de feature-extraction y fine-tuning previamente explicadas en el apartado 3.2. La Figura 15 refleja la proporción de las etiquetas contenidas en el dataset.




Figura 15 Distribución Conjuntos del Dataset

Puesto que se utilizará `RandomizedSearchCV` para la búsqueda de hiperparámetros no será necesario un conjunto de validación para el baseline (HOG+SVM), ya que este método realiza validación cruzada interna durante la selección de hiperparámetros.

En el contexto del FER, encontrar desbalanceo no es casualidad, sino que refleja la propia naturaleza de las emociones, estados como la felicidad o la neutralidad son más frecuentes en la vida cotidiana que el miedo o el asco. RAF-DB, es un claro ejemplo de ello, como se puede observar en la Figura 15, el dataset se encuentra desbalanceado de forma que la clase *Happy* supone un 38% del conjunto de entrenamiento mientras que *fear* representa apenas el 2,3%. En el proceso de entrenamiento, el clasificador tiene como finalidad minimizar el error global, por lo que cuando no existe una distribución uniforme, el modelo tiende a optimizar su rendimiento sobre las clases mayoritarias, aprendiendo representaciones más robustas para estas y penalizando en menor medida los errores cometidos sobre clases minoritarias.

Este hecho también resulta en que algunas métricas resulten engañosas, dando un accuracy alto, aunque el modelo ignore clases minoritarias.

Tras analizar las posibles técnicas de balanceo presentadas en el apartado 3.3, se decide trabajar con el dataset sin modificar su distribución original. Para ello, se aplicarán dos estrategias complementarias:

En primer lugar, se utilizarán métricas de evaluación adecuadas que reflejen el rendimiento de los modelos sin que los resultados se vean distorsionados por la distribución de clases, como se detalla en el apartado 4.3.2.

En segundo lugar, se aplicarán pesos de clase inversamente proporcionales a la frecuencia durante el entrenamiento mediante `compute_class_weight`. Esta técnica permite aumentar la penalización asociada a los errores cometidos en clases minoritarias, equilibrando parcialmente el efecto del desbalanceo sin alterar la distribución original del dataset.

4.3.2 Métricas de evaluación

Con la finalidad de evaluar el rendimiento de cada modelo, se marcan una serie de métricas que tendrán en cuenta el estado desbalanceado del dataset de forma que se pueda analizar el rendimiento del modelo sin que los resultados se vean distorsionados por la distribución de clases. Todos los modelos se evalúan sobre el mismo conjunto de test, garantizando comparaciones justas entre arquitecturas.

1. **Precisión y Recall:** Precisión mide la proporción de predicciones positivas correctas, mientras que Recall mide la proporción de instancias positivas correctamente identificadas. Estas métricas son especialmente relevantes en contextos de desbalanceo permitiendo evaluar el rendimiento en clases minoritarias.
2. **Macro F1-score:** permite evaluar el rendimiento promedio entre clases dando el mismo peso a cada una de ellas, independientemente de su frecuencia. Se calcula como la media entre Precisión y Recall por cada clase.
3. **Accuracy:** Aunque el accuracy puede verse afectado por el desbalanceo, se incluye para facilitar la comparación con trabajos previos y analizar la diferencia respecto a métricas más robustas (Macro-F1 y Balanced Accuracy).
4. **Balanced accuracy:** calcula la media del recall entre clases, proporcionando una medida menos sensible al desbalance.

Se incluyen **matrices de confusión** como herramienta de análisis cualitativo para identificar patrones de confusión entre emociones similares y analizar posibles sesgos en las predicciones de cada modelo

Además de las métricas mencionadas, se comparará la eficiencia computacional en términos de número de parámetros y tiempo de inferencia. Por otro lado, la evaluación se complementa con un análisis de robustez ante cambios geométricos y de iluminación, además de un análisis de explicabilidad con técnicas como Grad-CAM, Attention Rollout y análisis de prototipos y críticas, que se detallan en los posteriores apartados correspondientes.

4.3.3 Preprocesamiento

Dado que cada arquitectura presenta requisitos de entrada distintos, no resulta posible definir un único preprocesamiento común para todos los modelos. Por este motivo, se aplicó el mínimo preprocesamiento específico necesario para cada arquitectura, manteniendo condiciones equivalentes siempre que fue posible.

4.3.3.1 Preprocesamiento HOG+SVM

Previo a la extracción de características HOG, es necesario aplicar varios preprocesamientos, en primer lugar, una conversión a escala de grises, eliminando la información del color que no es relevante para HOG. Posteriormente, se realiza un redimensionado fijo a 64x64, asegurando una dimensionalidad uniforme de todas las imágenes. Esta resolución permite reducir el coste computacional manteniendo suficiente información estructural para la extracción de gradientes. Finalmente, se normaliza el valor de los píxeles a un rango [0,1].

Sobre la imagen ya preprocesada, se aplica el descriptor HOG (Histogram Oriented Gradients) con los siguientes parámetros: 9 orientaciones, (8,8) píxeles por celda, (2,2) celdas por bloque y normalización de bloques L2-Hys.

El vector de características resultante del HOG presenta una dimensión fija para todas las muestras y se introduce como input en el clasificador SVM sin procesamiento intermedio.

4.3.3.2 Preprocesamiento EfficientNetB3 y ResNet50

Con la finalidad de una comparación justa entre las CNNs, se comparte todo el preprocesamiento salvo la normalización específica de cada modelo.

Todas las imágenes son procesadas a color y redimensionadas a 224x224 píxeles, resolución estándar para ambas arquitecturas. Se aplica el preprocesamiento específico de cada modelo '*preprocess_input*', que presenta diferentes características en función del modelo. En el caso de EfficientNetB3, este preprocesamiento normaliza los píxeles al rango [0,1]. Para ResNet50, este preprocesamiento normaliza los valores de los píxeles restando a cada canal la media de intensidad calculada sobre *ImageNet* (dataset con el que fue entrenado ResNet). De esta forma, se centran los valores de

entrada en torno a cero, garantizando que la red funcione en el mismo rango numérico que con el que fue entrenada, evitando un desajuste de la distribución que perjudicaría la transferencia de conocimiento.

Con la finalidad de reducir el overfitting y mejorar la generalización, se realiza un aumento de datos sobre el *split* de entrenamiento, respetando la proporción original de los datos.

4.3.3.3 Preprocesamiento ViT-B/16

En el caso del Transformer, el preprocesamiento se delega en *AutoImageProcessor* del modelo *Google/vit-base-patch16-224-in21k* que se encarga de realizar un redimensionado a 224x224 píxeles, la normalización de los valores de los píxeles mediante la resta de la media de ImageNet y división por la desviación típica y una conversión a tensor *PyTorch*.

Para reducir overfitting y mejorar la capacidad de generalización, se aplica un aumento de datos mediante giros horizontales aleatorios (*RandomHorizontalFlip*) y perturbación de color con (*ColorJitter*).

4.3.4 Entorno de ejecución

Para el desarrollo y ejecución de las pruebas planteadas en el contexto de este trabajo se utilizó Python, con librerías *scikit-learn*, *TensorFlow/Keras* y *PyTorch* según el modelo en cuestión.

El entrenamiento de los modelos se realizó con la GPU de Google Colab. En concreto, debido a las restricciones propias de esta plataforma con respecto a la RAM y al tiempo de ejecución, el ViT fue entrenado en el servidor Arquímedes de la universidad, que también fue utilizado para el cálculo de todos los tiempos de inferencia de los modelos entrenados en Google Colab, asegurando que los resultados sean comparables.

4.3.5 Protocolo experimental

A continuación, se detallan las configuraciones específicas de entrenamiento para cada modelo evaluado.

4.3.5.1 HOG+SVM

El baseline de extracción de características se estructura como un pipeline de *scikit-learn* formado por un estandarizador *StandardScaler*, seguido de un clasificador SVM con kernel RBF. El desbalanceo de clases se gestiona mediante el *parámetro class-weight="balanced"* del SVC, que pondera inversamente las clases según su frecuencia.

La selección de hiperparámetros se realiza mediante *RandomizedSearchCV* con validación cruzada de tres particiones, optimizando F1-macro, explorando combinaciones según los parámetros, $C \in [0.1, 1, 10, 100, 1000]$ y $\text{Gamma} \in [0.001, 0.01, 0.1, 1]$. El modelo final se reentrena con los mejores hiperparámetros encontrados sobre el conjunto completo de entrenamiento.

4.3.5.2 EfficientNetB3 y ResNet50

Se empleó el mismo cabezal de clasificación para ambas CNN con el fin de aislar el efecto de la arquitectura base y garantizar una comparación homogénea. Ambas CNNs comparten estrategia de entrenamiento de transfer-learning, formada por un entrenamiento de dos fases. Sobre la salida del *backbone* se agrega un cabezal de clasificación formado por una capa *GlobalAveragePooling2D*, dos capas densas de 512 y 256 unidades con activación *ReLU*, regularización L2, *BatchNormalization* y *Dropout* y una capa densa final de siete unidades con activación *softmax*. El desbalanceo de clases se gestiona en ambos modelos mediante pesos calculados con *compute_class_weight("balanced")*, aplicados durante el entrenamiento.

La primera fase del transfer-learning entrena únicamente el cabezal de clasificación (*feature-extraction*) con *Adam* ($lr=1e-3$), durante un máximo de quince *epochs*. Se emplea *ReduceLROnPlateau* para reducir el *lr* a la mitad si *val_loss* no mejora durante tres *epochs* consecutivos y *EarlyStopping* con paciencia cinco para detener el entrenamiento anticipadamente, previniendo overfitting. En cada *epoch* se aplica un guardado del modelo con mejor *val_loss*.

La segunda fase (fine-tuning), descongela parcialmente el *backbone* (50 capas en ResNet, 130 capas de EfficientNetB3, cantidad determinada experimentalmente mediante validación para equilibrar capacidad adaptativa y estabilidad), manteniendo congelado el resto para conservar las representaciones de bajo nivel

aprendidas del preentrenamiento con ImageNet. En este caso, la tasa de aprendizaje se gestiona con *CosineDecayRestarts*, con un lr inicial de $3e-5$ y ciclo inicial de 1300 pasos en EfficientNetB3 y lr inicial de $1e-5$ con ciclo de 500 pasos en ResNet50. Esta estrategia permite realizar ajustes finos de los pesos preentrenados evitando cambios bruscos durante el fine-tuning. Se establece un entrenamiento de hasta 30 *epochs* con *EarlyStopping* y guardado del mejor *checkpoint*.

4.3.5.3 ViT-B/16

Para el transformer se parte de un modelo preentrenado *Google/vit-base-patch16-224-in21k* que divide cada imagen de 224x224 píxeles en 196 parches de 16x16 y los procesa con un encoder de 12 bloques de atención multi-cabeza. El desbalanceo es gestionado mediante un *WeightedTrainer* que reemplaza la función de pérdida por una *CrossEntropyLoss* ponderada con los pesos calculados mediante *compute_class_weight("balanced")*.

Se establece un entrenamiento de *transfer-learning* dividido en dos fases diferenciadas.

En primer lugar, en la fase 1 se congela todo el *backbone* y únicamente se entrena la capa de clasificación (*feature extraction*). El entrenamiento se realiza con *Adam* ($lr=3e-3$, $weight\ decay=0.01$) durante 10 *epochs*, seleccionando el *epoch* según el F1-macro en validación

Posteriormente, en fase 2 se descongelan los últimos dos bloques del encoder, manteniendo congelados los 10 bloques iniciales para preservar las representaciones aprendidas en el preentrenamiento con ImageNet. El *finetuning* se realiza con *Adam* ($lr=1e-5$, $decay = 0.01$) durante hasta quince *epochs*, seleccionando el *epoch* según el F1-macro en validación

4.3.6 Robustez

Tal y como se expone en el apartado 3.4, la robustez en FER puede analizarse según distintas variaciones, geométricas, de iluminación, degradación de la calidad de la imagen y variaciones demográficas. De estas variaciones en este trabajo se analizan

las tres primeras, ya que el conjunto de test no incluye etiquetado demográfico que permita analizar el efecto de la edad, etnia o género en el comportamiento del modelo.

Para evaluar la robustez, se reevaluaron todos los modelos sobre las mismas versiones perturbadas del conjunto de test. Para cada perturbación (Ver Figura 16) se siguió el mismo flujo de procesamiento: lectura y decodificación de la imagen original, redimensionado al tamaño de entrada del modelo, aplicación de la transformación correspondiente e inferencia por lotes sobre el modelo entrenado.




Figura 16 Tipos de perturbación para analizar la robustez

Para evaluar la robustez ante variaciones geométricas se evaluaron rotaciones de la imagen alrededor de su centro, implementadas con una transformación, en tres niveles (10°, 15° y 30°).

Para evaluar la robustez ante variaciones en la iluminación se aplicó un ajuste del brillo de la imagen, en incrementos de 0.15, 0.30 y 0.50 sobre los valores de píxel.

La robustez ante degradación de la calidad de la imagen se evaluó mediante dos tipos de degradación: por un lado, difuminado, implementado mediante un suavizado gaussiano, en tres niveles definidos por el tamaño del kernel (3, 5 y 7) y por mediante compresión JPEG, implementada codificando y decodificando la imagen con un factor de calidad reducido (calidad = 10), simulando la pérdida de información.

Para cuantificar el efecto de cada alteración se tuvo en cuenta el F1-Macro calculado primero sobre el conjunto sin perturbar y luego perturbado. El impacto de

cada perturbación se calculó como degradación relativa respecto al valor de original, calculada como se ve reflejado en la siguiente fórmula.

$$\text{Degradación} = \frac{F1_{original} - F1_{alterado}}{F1_{original}} \times 100$$

4.3.7 Técnicas de Explicabilidad

La finalidad del análisis de explicabilidad (Ver apartado 3.5) de los cuatro modelos desarrollados, HOG+SVM, ResNet50, EfficientNetB3 y ViT-B/16 no es describir los mapas de atención de forma independiente, sino evaluar el grado de coincidencia entre las regiones faciales que cada modelo considera relevantes y si sus estrategias son coherentes con el conocimiento experto sobre las expresiones faciales codificado en el sistema FACS y los AUs de cada emoción previamente planteados durante el apartado 2.1.

Para ello, se aplican las técnicas descritas durante el apartado 3.5 a cada modelo, Grad-CAM para EfficientNetB3, ResNet50 y ViT-B/16 y adicionalmente Attention roll-out para ViT dado que Grad-CAM no está específicamente diseñado para arquitecturas basadas en atención; junto con un análisis de la distribución en el espacio de representación mediante t-SNE para los modelos de deep learning.

En el caso concreto de HOG+SVM, la explicabilidad reside en la propia representación. HOG obtiene características diseñadas manualmente que capturan los gradientes en regiones locales de la imagen, por lo que su visualización es la propia explicación del sistema, sin necesidad de técnicas post-hoc. A diferencia de Grad-CAM y Attention-RollOut, que aproximan la importancia de cada región en función de gradientes internos, HOG es intrínsecamente explicable, lo que el modelo ve es directamente lo que se visualiza en su explicación.

En la Figura 17 podemos ver un ejemplo de la explicabilidad obtenida para la emoción Sorpresa por cada modelo analizado.

Todo el análisis de explicabilidad se ha realizado únicamente sobre el conjunto de test, asegurando que las imágenes no han sido vistas anteriormente por el modelo durante el entrenamiento. De esta forma, se asegura la consistencia con las métricas de

rendimiento obtenidas y evita cualquier sesgo derivado de la memorización de ejemplos de entrenamiento.




Figura 17 Comparativa general de explicabilidad en cada modelo analizado

Con el fin de que la comparación entre los modelos sea directa, se selecciona un conjunto fijo de imágenes de análisis estructurado, donde para cada una de las siete emociones se seleccionan cuatro muestras por clase, formando un conjunto de 21 imágenes.

El conjunto agrupa imágenes clasificadas correctamente por los tres modelos de Deep Learning (ResNet50, EfficientNetB3 y ViT), permitiendo analizar el comportamiento de cada arquitectura en condiciones de predicción exitosa. La selección de las muestras se realizó de forma aleatoria entre las imágenes que cumplieran el criterio, sin utilizar la confianza de ningún modelo como criterio de ordenación. Esto se realizó con la finalidad de lograr una selección neutra evitando sesgos que favorezcan a unos modelos por encima de otros y asegurando que los mapas resultantes sean comparables y obtenidos en igualdad de condiciones.

Además de los mapas de calor, se realiza un análisis de la distribución en el espacio de representación mediante la proyección t-SNE de los aciertos del conjunto de test (Ver apartado 3.5) de los embeddings internos de cada modelo que permite analizar cómo cada arquitectura organiza el espacio de representación, permitiendo una perspectiva global sobre la distribución de las clases. Este análisis no se realizará

sobre HOG+SVM al tratarse de un descriptor de características sin espacio de representación aprendido. Se tendrán en cuenta sólo las clases *Disgust*, *Fear*, *Anger* y *Happy* por razones de interpretabilidad y relevancia. *Happy* se incluye como clase de referencia dominante, mientras que *Disgust*, *Fear* y *Anger* son las emociones negativas con mayor confusión entre sí (Ver Capítulo 5 -), siendo su representación en el espacio un indicador relevante de la capacidad de cada modelo para diferenciar estas clases.

Complementariamente a la proyección t-SNE, se obtienen prototipos y críticas a partir de los aciertos del conjunto de test (Ver apartado 3.5) de EfficientNetB3, ResNet50 y ViT-B/16. Los prototipos son las imágenes cuyo embedding presenta menor distancia coseno al centroide de su clase, representando el ejemplo más típico de cada emoción según el modelo. Las críticas son los aciertos más alejados de dicho centroide, es decir, los ejemplos más atípicos que el modelo es capaz de clasificar correctamente, lo que aporta información sobre su capacidad de generalización. De esta forma, se complementa el análisis cuantitativo con una interpretación cualitativa de qué rasgos faciales el modelo asocia con cada emoción.

Aunque el análisis de explicabilidad se ha centrado en aciertos comunes del conjunto de test, la observación de las regiones de activación y la distribución de los embeddings en el espacio de representación permite inferir patrones de error indirectamente. Específicamente, emociones con activaciones coincidentes o representaciones difusas en el espacio latente revelarían mayor propensión a confusión entre clases, información que se extraerá durante el análisis de resultados.

Capítulo 5 - Análisis de resultados

Los resultados planteados en este apartado corresponden a la evaluación de los modelos planteados en el Capítulo 4 - . Todos los modelos han sido entrenados con el dataset RAF-DB y evaluados con un subconjunto test de 3.000 imágenes aproximadamente. Todos fueron entrenados y evaluados en condiciones idénticas, misma distribución de dataset, mismas métricas y mismo procesador. Esta uniformidad garantiza que las diferencias observadas sean atribuibles a las arquitecturas y no a factores externos.

Las métricas principales empleadas son accuracy, balanced accuracy y F1 macro, estas métricas fueron seleccionadas específicamente debido al estado desbalanceado del dataset previamente mencionado en el apartado 4.1, que provoca que la métrica accuracy pueda ser engañosa. Por su lado, F1 Macro y balanced accuracy resultan más representativas para el caso actual ya que ponderan las clases por igual independientemente de su frecuencia.

Más información sobre los resultados obtenidos en Apéndice B - .

5.1 Rendimiento

Previo a analizar la comparativa de los resultados, es importante contextualizar los valores que deben analizarse teniendo en cuenta algunos aspectos fundamentales.

El subconjunto de RAF-DB utilizado no representa la distribución completa del dataset original sino un subconjunto de aproximadamente 15.000 imágenes, lo que reduce significativamente la cantidad de muestras disponibles para el entrenamiento y limita la capacidad de los modelos para aprender representaciones robustas de cada clase. Además, este dataset está significativamente desbalanceado con clases como *happy* o *neutral* mucho más representadas que otras como *fear* o *disgust*, y aunque esta situación se mitiga con métricas específicas como se ha comentado en apartados anteriores, sigue afectando negativamente a los resultados y al entrenamiento provocando sesgo hacia clases mayoritarias.

La reducida cantidad de muestras afecta de forma distinta a cada modelo. Los modelos convolucionales (ResNet50 y EfficientNet-B3), diseñados para analizar las imágenes de forma local y jerárquica aprenden a extraer características útiles incluso con pocos datos, mientras que los transformers como ViT-B/16, requieren una mayor cantidad de muestras para alcanzar un rendimiento aceptable. En este contexto, se observa que, incluso en condiciones desfavorables, ViT-B/16 alcanza resultados comparables a EfficientNet-B3, lo que sugiere que su rendimiento podría mejorar significativamente con acceso al dataset completo.

En conclusión, los resultados no son directamente comparables con los reportados en investigaciones sobre RAF-BD donde los modelos son entrenados con el dataset completo. Por tanto, se dará mayor importancia a las métricas de balanced accuracy y F1-Macro por representar de forma más fiable el rendimiento de los modelos.

La Tabla 4, muestra la comparativa de los resultados obtenidos por los modelos en concepto de Accuracy, Balanced Accuracy y F1 Macro.

Modelo	Accuracy	Balanced Accuracy	F1 Macro
Baseline (HOG + SVM)	0.712	0.559	0.585
ResNet50	0.705	0.623	0.611
EfficientNet-B3	0.752	0.682	0.656
ViT-B/16	0.744	0.661	0.654

Tabla 4 Resultados Globales para cada modelo sobre RAF-DB

Como se observa, EfficientNet-B3 obtiene el mejor rendimiento en las tres métricas, con un F1-Macro de 0.656 y un balanced accuracy de 0.682, seguido muy de cerca con ViT-B/16 que alcanza 0.654 y 0.661 para las mismas métricas. De estos resultados, podemos deducir una capacidad similar a pesar de sus arquitecturas y número de parámetros claramente diferentes.

En el caso de ResNet50, supera al baseline en las métricas balanceadas, aunque se queda por detrás en el accuracy, con el valor más bajo de la comparación (0.705),

de lo que podemos deducir que ResNet es la arquitectura que presenta una mayor dificultad para generalizar sobre las clases minoritarias.

El baseline HOG-SVM por su parte, a pesar de su simplicidad, obtiene el segundo accuracy más alto (0.712). Sin embargo, tanto su balanced accuracy como su F1 Macro baja significativamente hasta 0.55 y 0.58 respectivamente, lo que muestra una clara dependencia de las clases mayoritarias, limitando su validez en un dataset desbalanceado como RAF-DB.

5.2 Análisis por clase

La Tabla 5, muestra la comparativa de los resultados obtenidos de la métrica F1-Macro por cada modelo y emoción.

Clase	Baseline (HOG+SVM)	ResNet50	EfficientNet-B3	ViT-B/16
Anger	0.60	0.58	0.64	0.60
Disgust	0.26	0.35	0.42	0.40
Fear	0.42	0.49	0.47	0.56
Happy	0.85	0.84	0.88	0.87
Neutral	0.69	0.66	0.71	0.73
Sad	0.61	0.67	0.73	0.67
Surprise	0.67	0.69	0.74	0.75

Tabla 5 Resultados F1 Macro por emoción y modelo evaluado

La comparativa por clase y modelo representada refleja gran diversidad de resultados en el rendimiento de los modelos. La clase Happy es consistentemente la mejor reconocida, con puntuaciones de F1 superiores a 0.84, lo que refleja tanto su alta representación en el dataset (siendo la clase predominante) como la claridad de los rasgos faciales fácilmente distinguibles del resto de emociones.

Por otra parte, *disgust* es la clase con peor rendimiento en todos los modelos (entre 0.26 y 0.42), seguida de *fear* (entre 0.42 y 0.56), ambas emociones presentan baja

frecuencia en el dataset y rasgos faciales sutiles, ambiguos y fácilmente confundibles con otras emociones.

Un aspecto relevante es la variabilidad en el rendimiento entre clases según la arquitectura. El baseline HOG+SVM presenta una dispersión muy elevada entre clases, con rendimientos que oscilan desde 0.26 en *Disgust* hasta 0.85 en *Happy*, lo que indica una gran dependencia de la claridad de los rasgos faciales y una capacidad limitada para generalizar equitativamente entre emociones. Por el contrario, EfficientNet-B3 demuestra un rendimiento más equilibrado y consistente, manteniendo puntuaciones relativamente uniformes incluso en las clases minoritarias. Esto sugiere que EfficientNet ha desarrollado representaciones más robustas e independientes de la distribución de clases, permitiendo un reconocimiento más fiable en todos los tipos de expresiones emocionales

Con respecto al rendimiento de los modelos, EfficientNetB3 destaca en las clases de *anger*, *sad* y *surprise*, mientras que ViT-B/16, se muestra ligeramente superior en *fear* y *neutral*, ambas clases cuya clasificación puede depender más de una capacidad de comprensión del contexto global de la imagen que de rasgos faciales concretos aislados.

5.3 Análisis matrices de confusión

El análisis conjunto de las matrices de confusión de los modelos entrenados (Apéndice A -) muestra dos patrones claros comunes a todos los modelos.

Por un lado, existe cierta tendencia hacia la clase neutral. Emociones con características sutiles o ambiguas como *disgust*, *sad* o *fear* tienden a clasificarse como neutral en todos los modelos, siendo este comportamiento especialmente frecuente en HOG+SVM cuya técnica basada en la extracción que carece de capacidad para detectar los detalles sutiles que diferencian estas emociones.

Por otro lado, existe una clara confusión bidireccional entre *anger* y *disgust*. Este hecho tiene sentido ya que ambas emociones comparten características faciales en la región de la nariz, el labio y el entrecejo, como se ve reflejado en la activación de los Aus según el FACS presentado en la Figura 1, haciendo que ambas emociones sean difíciles de distinguir incluso para los modelos más complejos. Esta confusión ocurre

especialmente en ResNet50, lo que podemos justificar con un problema de sobreajuste del modelo.

HOG+SVM presenta la mayor dispersión de predicciones erróneas, distribuidas entre clases, indicativo de su baja capacidad para diferenciar las emociones. Por otro lado, ResNet50 muestra tendencia clara a confundir *Fear* y *Disgust* y a clasificar erróneamente las clases minoritarias como *Happy*, *Neutral* o *Sad*, lo que nos hace intuir un sesgo hacia clases mayoritarias.

EfficientNet-B3 y ViT-B/16 presentan confusiones más localizadas. En el caso de EfficientNet-B3, destaca por sus diagonales claras y bien diferenciadas, especialmente *Happy* (1002 aciertos), *Sad* (345) y *Surprise* (261), con errores concentrados en confusiones razonables entre clases con AUs similares (como *Anger* y *Disgust*). ViT-B/16 muestra un patrón similar, aunque con ligera mayor dispersión en emociones minoritarias, algo consistente con su dependencia a grandes volúmenes de datos.

En conclusión, EfficientNet-B3 comete menos errores y presenta menor dispersión en sus predicciones incorrectas, consolidando su superioridad previamente observada en las métricas analizadas en el apartado 5.1.

5.4 Análisis de eficiencia

La Tabla 6, muestra la comparativa de los modelos en función de su año de publicación, número de parámetros y tiempo inferencia por imagen en GPU y CPU.

Modelo	Año	Parámetros	Tiempo de Inferencia GPU	Tiempo de Inferencia CPU
Baseline (HOG + SVM)	2005	No Aplicable	No Aplicable	15,06 ms/img
ResNet50	2015	24,8M	14,26 ms/img	48,19 ms/img
EfficientNet-B3	2019	11,7M	15,53 ms/img	72,75 ms/img
ViT-B/16	2021	85,8M	4,84 ms/img	43,16 ms/img

Tabla 6 Comparativa de eficiencia computacional de los modelos evaluados

Los resultados obtenidos muestran una clara relación inversa entre el número de parámetros y el tiempo de inferencia. ViT-B/16 con 85,8 millones de parámetros, una cantidad varias veces superior a la de las redes neuronales profundas (EfficientNetB3 con 11,7M y ResNet50 con 24,8M), resulta ser el modelo más rápido en GPU. Esto ocurre porque los Transformers realizan principalmente multiplicaciones matriciales grandes, que las GPUs modernas están muy optimizadas para ejecutar. Las redes convolucionales, por su parte, hacen muchas operaciones diferentes (convoluciones de distintos tamaños, normalizaciones...), cada una requiere tiempo de inicio en la GPU. Aunque teóricamente el mecanismo de atención de los Transformers consume más cálculos (pues la atención compara cada parche de imagen con todos los demás), en la práctica la GPU lo paraleliza tan bien que resulta más rápido que las convoluciones encadenadas.

Cuando se ejecutan los modelos en CPU, ViT-B/16 tiene una degradación superior a la del resto de modelos, siendo casi 9 veces más lento en CPU (43,16 ms/img). Por su parte, ResNet50 y EfficientNetB3 presentan una degradación más moderada, aunque sus tiempos de inferencia siguen siendo superiores (48,19ms/img y 72,75 ms/img respectivamente). Estos resultados responden al hecho de que ViT-B/16 está específicamente diseñado para ejecutarse en GPUs.

Si nos fijamos en el baseline HOG+SVM, que por su diseño está únicamente disponible para ejecutarse en CPU, observamos que, aunque es un método antiguo, sigue siendo competitivo en velocidad. ResNet50 en GPU es ligeramente más rápido (14,26 ms), pero solo porque tiene una GPU acelerada. Si ejecutas ResNet50 en CPU, es varias veces más lento. Esto muestra que la ventaja del deep learning en velocidad depende mucho de tener GPU disponible. Si no la tienes, los métodos clásicos siguen siendo razonables con concepto de eficiencia computacional.

En conclusión, ViT-B/16 es significativamente más rápida en GPU (4,84 ms/img) que cualquiera de los modelos analizados y presenta una diferencia de precisión en comparación con EfficientNetB3, el modelo con mejor F1-Macro, muy baja (F1-Macro 0.654 vs 0.656, respectivamente). En GPU, ViT ofrece una mejor relación velocidad-precisión y aunque un paso a CPU afecta mucho más a ViT que al resto de modelos,

este sigue siendo significativamente más veloz que EfficientNet, manteniéndose como el modelo con mejor relación velocidad-precisión entre los comparados.

5.5 Robustez

Tras la realización de las pruebas de robustez planteadas en el apartado 4.3.6, se evaluaron para cada modelo cuatro tipos de degradación, desenfoque (Blur), variación de brillo, rotación y compresión, observándose los resultados reflejados en la Figura 18 como el porcentaje de degradación medio de F1-Macro para el conjunto de muestras de test en función de la degradación y el modelo.




Figura 18 Resultados en porcentaje de degradación por modelo y alteración

El desenfoque (Blur) simula un problema de enfoque, un suceso muy común por ejemplo en cámaras de móvil. Se observa que ViT-B/16 resulta muy robusto (0,4%-2,4%), seguido de EfficientNetB3 (0,7%-7,7%), ambos manteniendo su rendimiento incluso ante desenfoques severos. Por su parte, ResNet50 resulta más sensible al desenfoque, llegando a una degradación del 14% en el peor escenario. HOG+SVM es el modelo que peor resiste esta degradación (41,1%), esto es resultado de su dependencia a los gradientes locales precisos que se pierden con el desenfoque.

La rotación que evalúa el comportamiento del sistema ante cambios de pose, algo muy relevante en escenarios no controlados, resulta ser la degradación más perjudicial para todos los modelos. EfficientNetB3 se mantiene más robusto que los

demás, aunque sus degradaciones llegan hasta el 28,4% para la rotación de 30°. ViT-B/16 muestra una degradación grave incluso para rotaciones leves (19.4%), superada únicamente por HOG+SVM. Este comportamiento contrasta con su robustez al desenfoque, sugiriendo que, aunque su procesamiento por parches lo hace robusto ante otras alteraciones, esta estrategia requiere alineamiento consistente de regiones relevantes. Por su parte, HOG+SVM resulta ser el método más afectado con una pérdida de hasta el 78%.

Los cambios de brillo e iluminación resultan relevantes al tratarse de una alteración inevitable (diferentes horarios, condiciones meteorológicas...). Para esta alteración, los modelos presentan un comportamiento relativamente equilibrado, manteniendo degradaciones bajas incluso para cambios de brillo leves y moderados, aunque empeorando en casos de cambios graves de brillos llegando a un 44% de degradación.

Finalmente, la compresión JPEG resulta importante analizarla al representa un suceso inevitable en sistemas reales, la degradación de la calidad de la imagen por transmisión de red o almacenamiento. Para este caso, EfficientNetB3 mantiene el mejor rendimiento (12% de degradación), seguido de cerca por ViT-B/16 (16,2%). Esta degradación resulta moderada y severa en ResNet50 y HOG+SVM (22% y 24% respectivamente)

En general, EfficientNetB3 resulta más robusto a nivel global con una degradación consistente para cada tipo de degradación con una media de 14,1%, este comportamiento puede explicarse con los mecanismos de Batch Normalization y Squeeze and Excitation (que recalibran la importancia por canales) expuestos en el apartado 2.5.2 que mantienen las activaciones estables ante alteraciones.

ViT-B/16 por su parte resulta especialmente robusto al desenfoque y al cambio de brillo, aunque también resulta vulnerable a las rotaciones. Esta vulnerabilidad sugiere que, aunque el procesamiento por parches lo hace resistente en el resto de las alteraciones, esto requiere un alineamiento consistente de las regiones relevantes. ViT-B/16 resultará preferible en casos donde la robustez ante el desenfoque resulte una prioridad.

ResNet50 presenta robustez moderada, tiene un rendimiento moderado en desenfoque y rotación leve, pero sufre en brillo severo y compresión JPEG. Su degradación promedio del 20.5% lo sitúa como opción intermedia viable solo si se asegura preprocesamiento para brillo.

HOG+SVM es claramente inadecuado para aplicaciones reales, con vulnerabilidad grave ante la rotación (degradación promedio 53,3%) y el desenfoque severo. Su degradación promedio del 30,7% lo descalifica para cualquier escenario no controlado.

Capítulo 6 - Análisis de Explicabilidad

Durante este apartado se exponen los resultados de explicabilidad obtenidos de las pruebas realizadas según lo expuesto en el apartado 4.3.7, incluyendo el análisis mediante Grad-CAM, Attention-Rollout y la proyección t-SNE de los espacios de representación.

En concreto, el análisis de los mapas se realiza en contraste con el sistema de codificación de activación facial (FACS) que descompone cada emoción en unidades de activación musculares (AUs), previamente analizado en el apartado 2.1. Esta comparación permite evaluar en qué medida las regiones que el modelo considera relevantes coinciden con las regiones anatómicas que en psicología se identifican como informativas para cada emoción.

6.1 Explicabilidad en EfficientNetB3

En la Figura 19, se muestran los mapas de activación de Grad-CAM generados para EfficientNetB3 para casos de acierto común a todos los modelos para cada clase, mostrando para cada emoción cuatro muestras.




Figura 19 Grad-CAM EfficientNet, aciertos por emoción

En la emoción de ira, los mapas de activación se concentran en la región de las cejas y el entrecejo, con extensiones hacia la zona de la boca. Esta distribución es coherente con las AUs características de esta emoción según el FACS, la AU7 (bajada y aproximación de cejas, acción del músculo corrugador y depresor superciliar), la AU5 (elevación del párpado superior), la AU24 (tensión de los labios) y la AU25 (separación de los labios).

En el caso del asco, los mapas muestran una activación intensa en la zona de la nariz y el contorno de la boca, con especial énfasis en el labio superior y las mejillas. Esto se corresponde con las AUs prototípicas del asco como la AU9 (arrugado de la nariz), la AU15 (comisuras labiales hacia abajo) y la AU16 (descenso del labio inferior).

Para el miedo, los mapas de calor presentan una distribución más difusa y variable entre los ejemplos. Las AUs asociadas al miedo incluyen la AU1 y AU2 (elevación medial y lateral de las cejas), la AU4 (fruncimiento), la AU5 (apertura de los ojos) y la AU20 (estiramiento horizontal del labio).

La emoción de alegría genera activaciones claramente focalizadas en la zona de los pómulos y la boca, con extensiones hacia los ojos. Esto es consistente con las AUs de la sonrisa, la AU6 (elevación de las mejillas) y la AU12 (elevación de la boca). La combinación de estas dos unidades es el criterio diferenciador entre la sonrisa auténtica y la sonrisa social en el FACS, y el hecho de que el modelo active ambas regiones sugiere que ha internalizado este patrón discriminativo.

La clase neutral muestra los mapas de activación más difusos y de menos intensos, dispersándose por diversas zonas del rostro sin una focalización concreta. Este comportamiento es esperable ya que la expresión neutral carece de AUs dominantes que orienten al modelo. La activación distribuida podría interpretarse como un intento del modelo para detectar la ausencia de patrones específicos.

En la tristeza, los mapas concentran la activación en la zona central de las cejas y la comisura del labio. Esta distribución se alinea con las AUs características: la AU1 (elevación del ángulo interno de la ceja), la AU4 (fruncimiento del entrecejo) y la AU15 (descenso de las comisuras labiales). La concentración en la zona entre las cejas es

coherente con el FACS, ya que la activación aislada de la AU1, sin la AU2, es uno de los indicadores más fiables de tristeza frente a otras emociones.

Finalmente, la sorpresa muestra activaciones en la región de los ojos y la frente, con participación de la zona bucal en varios ejemplos. Esto corresponde a las AUs típicas para esta emoción AU1 y AU2 (elevación de toda la ceja), AU5 (apertura máxima del ojo) y AU25 (apertura mandibular). La activación simultánea de la región ocular superior y la bucal inferior refleja el patrón de apertura típico de esta emoción en el FACS.

En conclusión, el análisis Grad-CAM revela que EfficientNetB3 ha aprendido patrones de reconocimiento coherentes desde el punto de vista psicofisiológico. En general, las áreas activadas coinciden con las AUs establecidas por el FACS para cada emoción, lo que indica que el modelo no solo clasifica correctamente las emociones, sino que basa sus decisiones en las mismas regiones faciales que los sistemas expertos consideran relevantes. No obstante, se observa cierta variabilidad entre los cuatro ejemplos presentados para cada emoción, lo que sugiere que el modelo es capaz de adaptarse a las distintas formas en que las personas expresan sus emociones, en lugar de depender de un único patrón de referencia. Esta capacidad resulta especialmente útil dada la gran variabilidad que existe en la expresión de las emocionales.

6.2 Explicabilidad en ResNet50

Los mapas Grad-CAM de ResNet50 (Figura 20) muestran una estrategia de reconocimiento más difusa que la vista anteriormente en EfficientNetB3. En general, las activaciones tienden a cubrir zonas amplias del rostro, lo que dificulta su concordancia con las unidades de acción del FACS.

En la ira, la activación se concentra principalmente en la región de la boca, ignorando el entrecejo (AU4) que es la zona más relevante según el FACS. Esta atención única en la región bucal es coherente con la confusión bidireccional entre anger y disgust observada en las matrices de confusión del apartado 5.3, ya que ambas emociones comparten activaciones en el contorno de la boca. En el asco, se observa variabilidad preocupante entre ejemplos, sin centrarse en ninguna de las AUs relevantes para esta emoción. El miedo presenta la mayor heterogeneidad espacial, activando en

algunos ejemplos la zona de la boca y los ojos, combinación que el FACS considera más informativa para esta emoción.




Figura 20 Grad-CAM ResNet50, aciertos por emoción

La alegría es la categoría con mayor coherencia anatómica, activando correctamente la zona de mejillas y boca (AU6 y AU12). La categoría neutral al igual que en EfficientNet muestra gran dispersión de los mapas de calor, coherente con una clase que no presentan expresiones dominantes, salvo una ausencia de las mismas. La tristeza focaliza razonablemente la región ocular superior, y la sorpresa es la emoción con mapas más consistentes y alineados con el FACS, activando correctamente las regiones de la frente y los ojos.

En conclusión, ResNet50 muestra representaciones internas menos relacionadas con las regiones musculares específicas del FACS que EfficientNetB3. Esta menor precisión anatómica es coherente tanto con los mapas de confusión más dispersos como con su rendimiento (accuracy, balanced accuracy y F1-Macro) más bajo, lo que sugiere patrones aprendidos menos válidos.

6.3 Explicabilidad en ViT-B/16

Los mapas Grad-CAM del Vision Transformer ViT-B/16 (Figura 21) presentan un patrón claramente diferenciado respecto a los modelos convolucionales analizados anteriormente. La naturaleza de los ViTransformers basada en mecanismos de atención sobre parches de imagen produce activaciones más distribuidas y con mayor cobertura facial, lo que refleja la capacidad del modelo para integrar información contextual global en lugar de depender de características locales, lo que, en el contexto de las expresiones faciales, donde se deben tener en cuenta diversas zonas del rostro, puede resultar una ventaja.




Figura 21 Grad-CAM ViT-B/16, aciertos por emoción

En la ira, las activaciones cubren de forma amplia el rostro completo, incluyendo boca, mejillas y frente simultáneamente. El asco muestra activaciones centradas en la zona media del rostro con coherencia razonable respecto a las AU9 y AU15. El miedo presenta activaciones en boca y ojos, combinación que el FACS considera relevante. La alegría es la categoría más consistente, con activaciones en mejillas y boca correspondientes a las AU6 y AU12. La categoría neutral muestra la mayor dispersión, coherente con la ausencia de AUs dominantes. En tristeza, los mapas activan el tercio

superior del rostro y el contorno ocular, alineándose con las AU1 y AU4. La sorpresa presenta activaciones en frente y ojos, coherentes con las AU1, AU2 y AU5.

Sin embargo, dado que Grad-CAM no está diseñado para arquitecturas transformer basadas en la atención, sus mapas son los menos precisos de los tres modelos, mostrando mapas de calor muy difusos (Ver apartado 3.5). Para obtener una explicabilidad adecuada a esta arquitectura, se complementa el análisis con Attention Rollout (Figura 22), técnica que recorre las matrices de atención de cada capa revelando qué regiones reciben mayor atención del token de clasificación en cada una de las 12 cabezas del modelo.




Figura 22 Attention-RollOut en ViTransformer

Se observa una especialización progresiva de las cabezas de atención conforme aumenta la profundidad de la red. En las capas iniciales, las cabezas presentan activaciones con un alcance global, lo que permite al Transformer integrar información de toda la imagen desde los niveles más bajos. Este comportamiento evoluciona hacia las capas profundas, donde la atención se refina para capturar representaciones más abstractas y centrarse en regiones semánticamente relevantes para la tarea de clasificación[55]. Además, se observan de forma repetida activaciones sobre ojos y

comisuras labiales, propiedad anatómica coherente con el FACS donde la mayoría de AUs se activan. En ira y miedo, las cabezas profundas focalizan boca abierta y región ocular conjuntamente, con mayor coherencia FACS que la observada con Grad-CAM. En sorpresa, múltiples cabezas activan consistentemente ojos y frente, con cabezas tardías añadiendo la boca abierta, correspondiendo bien con las AU1, AU2, AU5 y AU26. En neutral y alegría, los mapas de *rollout* son más difusos, sugiriendo que el modelo se apoya en patrones globales para estas categorías.

En conjunto, ViT-B/16 destaca por mapas de activación más difusos debido a su procesamiento global por parches. Esto implica que, si bien el modelo es competitivo en rendimiento clasificatorio, su explicabilidad mediante Grad-CAM es la menos precisa anatómicamente de los tres modelos, ya que la propia arquitectura transformer no está diseñada para la localización espacial fina que el FACS requiere para una interpretación AU por AU. Esta situación queda resuelta con la aplicación de Attention-Rollout, que confirma que ViT-B/16 sí captura información relevante desde la perspectiva de FACS. Combinar ambas técnicas aporta una visión completa de la estrategia de reconocimiento del modelo.

En comparación con los modelos convolucionales, ViT-B/16 presenta una estrategia de reconocimiento muy distinta, global y distribuida por todo el rostro que refleja su comportamiento interno basado en la atención sobre parches frente a la extracción local jerárquica propia de las redes convolucionales.

6.4 Explicabilidad en HOG+SVM

A diferencia de los modelos convolucionales y el ViT, HOG+SVM no requiere técnicas de explicabilidad externas como Grad-CAM, sino que es un modelo intrínsecamente explicable mediante visualizaciones de gradientes orientados (Figura 23) que representan directamente las características que el modelo utiliza para clasificar. Este es el único modelo entre los comparados cuya explicabilidad es una propiedad propia de la arquitectura y no una técnica aplicada posteriormente.

La característica más llamativa es la homogeneidad visual de los descriptores entre emociones, independientemente de la emoción, los patrones de gradiente son prácticamente idénticos, capturando la estructura global del rostro sin ningún

mecanismo de atención selectiva. Esto implica una alineación con el FACS limitada, ya que HOG representa todas las regiones faciales con igual peso sin poder priorizar las AUs diagnósticas de cada emoción.




Figura 23 Representación de gradientes HOG+SVM, aciertos por emoción

Esta limitación se refleja directamente en su bajo F1-Macro, un resultado esperable dado que las emociones implican deformaciones musculares sutiles difíciles de capturar con un descriptor global. Esta limitación es coherente con la tendencia hacia la clase neutral observada en las matrices de confusión del apartado 5.3, al no poder detectar cambios musculares sutiles, el modelo tiende a clasificar como neutral aquellas emociones que no generan gradientes bruscos. Sin embargo, algunas emociones como alegría, miedo y sorpresa presentan mayor acierto al involucrar AUs de gran movimiento muscular (boca u ojos muy abiertos) que generan gradientes altos más fácil de distinguir.

En conjunto, HOG+SVM presenta un contraste, su funcionamiento es completamente transparente e interpretable, pero esa misma transparencia muestra su incapacidad para replicar la lógica selectiva del FACS, limitándolo a emociones con expresiones físicamente intensas.

6.5 Conclusión de explicabilidad basada en Grad-CAM y Attention-RollOut

Tras el análisis realizado mediante Grad-CAM y mapas de gradientes, se observa que EfficientNetB3 es el modelo con mayor validez de coherencia anatómica, generando activaciones localizadas y consistentes que se corresponden con las AUs del FACS en la mayoría de las emociones, lo que resulta coherente con su accuracy más alto. ResNet50 muestra representaciones más globales y difusas. ViT-B/16 alcanza confianzas elevadas gracias a su integración contextual global, aunque sus mapas Grad-CAM son los menos precisos espacialmente debido a su mecanismo basado en la atención, requiriendo Attention-RollOut para una interpretación anatómicamente coherente, donde se puede observar activaciones coherentes con el FACS. HOG+SVM queda claramente por detrás, a pesar de ser interpretable por naturaleza, su descriptor uniforme carece de selectividad espacial, lo que lo hace funcional solo para emociones con expresiones de alta intensidad muscular y lo sitúa como la opción menos adecuada tanto en rendimiento como en explicabilidad anatómica.

En conjunto, los resultados sugieren coherencia entre el rendimiento en clasificación y la coherencia anatómica, los modelos que aprenden activaciones relevantes según el FACS tienden a cometer menos errores de clasificación, mientras que modelos con activaciones más difusas muestran un peor rendimiento en clasificación.

6.6 Distribución en el espacio de representación

Complementando al análisis de Grad-CAM y Attention-Rollout, se analiza la distribución en el espacio de representación interno de cada modelo.

Analizando la proyección t-SNE de los embeddings internos de cada modelo se observa que EfficientNetB3 (Ver Figura 24) muestra la estructura más clara y separada de los tres modelos. Las clases disgust, fear y anger forman clusters compactos y bien diferenciados en la zona izquierda e inferior del espacio, con sus centroides claramente alejados entre sí. La clase happy, que presenta un desequilibrio de muestras notable, ocupa una región amplia, lo que resulta coherente con el estado desbalanceado del dataset que favorece significativamente a esta clase (Ver apartado 4.1). Esta

distribución indica que EfficientNetB3 ha aprendido a distinguir estas emociones separándolas de forma clara y consistente.




Figura 24 Distribución de clases y prototipos EfficientNetB3

En ResNet50 (Ver Figura 25), la división de los clusters se empeora. Las clases disgust, fear y anger aparecen más dispersas y se mezclan más entre sí, y sus centroides quedan inmersos en zonas con muestras de happy. Únicamente fear mantiene cierta agrupación en la zona inferior derecha, mientras que anger y disgust están más desordenadas y no forman grupos claros. Esta falta de orden en el espacio es coherente con los mapas Grad-CAM más difusos observados anteriormente y con su menor accuracy, confirmando que las representaciones internas de ResNet50 son menos discriminativas.

En ViT-B/16 (Figura 26), fear y anger forman un cluster compacto en la zona superior, bien separado del resto, aunque su proximidad entre sí indica que el modelo tiene dificultades para distinguirlas mutuamente, lo cual es coherente con el solapamiento de AUs que comparten ambas emociones. Disgust aparece dispersa y con su centroide próximo al de happy, lo que probablemente refleja el efecto del desequilibrio de muestras de esta clase sobre la organización global del espacio de representación.




Figura 25 Distribución clases y prototipos en ResNet




Figura 26 Distribución de clases ViT-B/16

En conjunto, el análisis t-SNE confirma y complementa las conclusiones del análisis Grad-CAM: EfficientNetB3 aprende el espacio de representación más estructurado y discriminativo, ResNet50 el menos organizado, y ViT-B/16 muestra una organización selectiva que separa bien algunas emociones, pero no todas. La coherencia entre la

calidad de los embeddings y el accuracy de cada modelo refuerza la validez del análisis de explicabilidad realizado.

6.7 Prototipos y críticas

Se identifican los prototipos y críticas de cada modelo para obtener una interpretación de qué ejemplos anclan las representaciones internas de cada clase y cuáles resultan más ajenos (Ver Apéndice A -).

En EfficientNetB3, los prototipos muestran expresiones faciales nítidas y confianzas muy elevadas en todas las clases, resultados coherentes con el espacio de representación t-SNE analizado previamente que muestra clusters compactos y bien definidos. Las críticas permiten intuir que el modelo es capaz de generalizar correctamente ante imágenes degradadas o con expresiones atípicas como el llanto infantil, aunque con confianzas notablemente más bajas.

En ResNet50, los prototipos presentan una mayor variabilidad visual y confianzas moderadas, coherente con los clusters menos compactos observados en el t-SNE. Las críticas muestran que el modelo generaliza ante imágenes con expresiones ambiguas entre anger y disgust, aunque con menor consistencia que EfficientNetB3, lo que es coherente con la confusión entre ambas clases observada previamente en las matrices de confusión.

En ViT-B/16, las críticas incluyen imágenes con oclusiones parciales o perfiles laterales, lo que indica que el modelo es capaz de clasificar correctamente ejemplos visualmente muy alejados del patrón típico, aunque con confianzas generalmente bajas.

En conjunto, este análisis refuerza las conclusiones previas, EfficientNetB3 presenta los prototipos más coherentes y las críticas más interpretables, lo que confirma representaciones internas robustas y bien relacionadas en los rasgos faciales relevantes. ResNet50 y ViT-B/16 muestran capacidad de generalización, pero menos estructurada, coherente con sus limitaciones ya observadas previamente.

Capítulo 7 - Conclusiones y trabajo futuro

En este trabajo se ha realizado un estudio comparativo de cuatro modelos de visión artificial para el reconocimiento de expresiones faciales (FER), cada modelo presenta distintos niveles de complejidad, reflejando el progreso de la tecnología a lo largo del tiempo. Se ha evaluado desde un enfoque clásico basado en extracción de características (HOG+SVM) hasta modelos de aprendizaje profundo como ResNet50 y EfficientNetB3, junto con arquitecturas basadas en mecanismo de atención como ViT-B/16. Los resultados obtenidos demuestran que la elección de una arquitectura u otra no puede basarse en un único factor sino en un balance entre rendimiento, eficiencia y explicabilidad.

EfficientNetB3 destaca como el modelo con mejor rendimiento global, alcanzando un F1-Macro de 0.656, con una arquitectura de tamaño moderado (11.9M de parámetros) y una latencia moderada de 15.53 ms/img en GPU, que degrada hasta 72.75ms/img en CPU. El análisis mediante los mapas de Grad-CAM muestra que EfficientNetB3 ha aprendido representaciones diferenciadas entre las emociones, correspondientes con patrones de reconocimiento anatómicamente coherente con el FACS. Además, su robustez resulta consistente ante perturbaciones, con una degradación media del 14.1%.

ViT-B/16 obtiene un rendimiento comparable al de EfficientNetB3 (F1-Macro de 0.654), y aunque presenta una cantidad de parámetros muy superior (85.8M) tiene la menor latencia entre los modelos comparados con 4.84ms/img en GPU y aunque degrada mucho más que EfficientNetB3 sin GPU, sigue siendo el modelo más rápido con 43.16ms/img. El análisis de Grad-CAM, Attention Rollout y t-SNE sugiere que el modelo no siempre aprende representaciones claramente separadas entre emociones, aunque sí muestra patrones de atención coherentes con el FACS. En términos de robustez, destaca frente a cambios de brillo y compresión, aunque resulta especialmente vulnerable a las rotaciones. Aun así, su rendimiento es notable considerando que ha sido entrenado con un conjunto de datos reducido para una arquitectura que habitualmente requiere grandes volúmenes de datos.

ResNet50 tiene un rendimiento intermedio (F1-Macro de 0.611), sin destacar especialmente en ninguna de las dimensiones analizadas. Sus representaciones internas resultan menos diferenciadas, con una mayor tendencia a confundir emociones visualmente similares.

Por su parte, HOG+SVM presenta el peor rendimiento entre los modelos comparados (F1-Macro de 0.585). Aunque es un modelo intrínsecamente explicable, no tiene capacidad para diferenciar expresiones sutiles, pudiendo identificar únicamente expresiones con cambios musculares muy marcados. Resulta también el modelo con menor robustez frente a las alteraciones analizadas. Finalmente, con respecto a este modelo resulta interesante mencionar que, a pesar de ser un método clásico que se ejecuta únicamente en CPU, su latencia resulta competitiva con la de los modelos analizados ejecutados en GPU (15.06ms/img).

Un hecho relevante recae sobre la relación aparentemente inversa entre complejidad y eficiencia, el ViT-B/16 con 85.8M de parámetros supera en velocidad a modelos significativamente más pequeños. Esto sugiere que métricas como el número de parámetros no resultan suficientes para predecir el rendimiento de un modelo.

El análisis de explicabilidad realizado revela que aquellos modelos que han aprendido patrones anatómicamente coherentes con el FACS tienden a cometer menos errores. Esta relación refuerza el valor de la explicabilidad, no solo como herramienta para interpretar, sino como un mecanismo de validación del comportamiento de los modelos.

Con respecto a la robustez, EfficientNetB3 demuestra ser el modelo más resistente globalmente (degradación media de 14.1%), mientras que ViT-B/16 presenta una robustez más selectiva, resultando vulnerable ante rotaciones, ResNet ocupa una posición intermedia, con una degradación media de 20.5%, y HOG+SVM resulta el más vulnerable con una media de 30.7%.

En conjunto, todos los resultados obtenidos confirman que la evaluación de sistemas de reconocimiento facial de emociones debe realizarse desde múltiples aspectos considerando simultáneamente precisión, eficiencia, robustez e

interpretabilidad. Bajo esta perspectiva, EfficientNetB3 se sitúa como la alternativa más equilibrada entre las arquitecturas estudiadas.

Trabajo a futuro

Como trabajo a futuro, se considera la posibilidad de ampliar el estudio con el dataset completo de RAF-DB u otros conjuntos de datos, con el objetivo de evaluar de forma más rigurosa la capacidad de generalización de los modelos, especialmente mediante el reentrenamiento del ViT-B/16 el cual presenta una alta dependencia a grandes cantidades de datos y cuyo modelo podría beneficiarse de conjuntos de datos de mayor tamaño.

A su vez, resulta relevante ampliar el análisis incorporando nuevas arquitecturas, tanto basadas en transformers como redes neuronales convolucionales más recientes, con el fin de obtener una comparación más completa del estado del arte.

En cuanto a robustez, se propone incluir evaluaciones demográficas para analizar el comportamiento de los modelos frente variaciones en edad, género o etnia, permitiendo detectar posibles sesgos en su desempeño.

Finalmente, el trabajo podría extenderse hacia un entorno de despliegue real, realizando pruebas de validación en entorno reales con usuario finales, lo que permitiría evaluar de manera más precisa su aplicabilidad práctica.

Introduction

Motivation

Facial expression recognition (FER) is a well-established task within computer vision that encompasses a wide range of approaches, ranging from classical methods, based on manual feature extraction and classification techniques, to more complex approaches grounded in deep learning techniques.

Various elements of verbal and non-verbal communication are useful to us in identifying emotions. In particular, facial expressions are especially informative, as they provide information about a person's mood. In this context, and alongside the rise of artificial intelligence (AI), machines have acquired the ability to analyze and classify facial emotions.

These advances are, in turn, of great significance in the social sphere as they facilitate the identification of emotions, a key aspect of communication. In particular, this technology is useful for people who struggle with emotional interaction, such as those with visual impairments or autism spectrum disorders, thereby facilitating their interaction with their surroundings.

This context highlights the need to analyze which current approaches are most suitable; specifically, this project aims to carry out a detailed comparison of different technical approaches for facial emotion classification, employing both more traditional computer vision techniques based on feature extraction and more modern deep learning techniques, in order to analyze their advantages and limitations. Furthermore, given that all the models to be considered have been pre-trained on ImageNet, this study enables an analysis of the ability of different architectures to generalize through transfer learning to complex tasks within a specific domain with limited data, such as facial emotion recognition.

Goals

The main aim of this study is to conduct a comparative analysis of different deep learning architectures applied to facial emotion recognition, evaluating their performance, efficiency and behavior.

To achieve this overall aim, the following specific objectives have been set:

1. **State-of-the-art review.** To analyze the current state of the art regarding facial emotion recognition using computer vision and deep learning techniques.
2. **Definition of a classical baseline.** In order to contextualize the results obtained and demonstrate the necessity and improvement offered by deep learning architectures, a classical computer vision method based on manual feature extraction and subsequent classification will be included as a baseline.
3. **Selection of representative architectures.** Select representative architectures for comparative study, following a progression ranging from classical methods of manual feature extraction to modern deep learning architectures, in order to conduct comparative study that allows for the contextualization of their performance, efficiency and behavior in facial emotion recognition.
4. **Implementation and performance evaluation.** Implement and train selected architectures using feature extraction and fine-tuning strategies. The selected models are based on a common pre-training on ImageNet, which allows us to isolate the impact of the architecture as an independent variable and, in turn, analyse the models' generalisation ability for complex tasks with limited data, such as facial emotion recognition. The performance of the models was subsequently evaluated using classification metrics, as well as criteria for computational efficiency and robustness
5. **Explainability analysis.** Deep learning-based architectures have limited interpretability due to their black-box nature. The models' decision-making process will be analysed using post-hoc explainability techniques. In particular, visual methods such as Grad-CAM and attention maps will be employed to identify which facial regions influence the predictions made by each architecture. Finally, the results obtained will be compared, identifying the advantages and limitations of each model.

Work plan

This work has been structured according to a phased approach with the aim of achieving the objectives set out.

Firstly, a review of the state of the art was conducted, analysing previous research related to facial expression recognition. This analysis provided an understanding of the current landscape and justified the selection of the dataset and techniques that were employed and compared throughout the study.

Subsequently, each selected technique was implemented, beginning with a common pre-processing step to ensure a fair comparison. Only the specific pre-processing strictly necessary for the correct functioning of each model was carried out.

Each model was trained using feature extraction and fine-tuning, starting from weights pre-trained on ImageNet, whilst discarding those pre-trained specifically for FER, in order to ensure equivalent conditions and to study each model's ability to adapt from a general domain to a more specific and complex one.

Finally, based on the results obtained, the performance, efficiency and robustness of each model against image-degrading artefacts were analysed and compared, along with their interpretability, in order to identify behavioural patterns and significant differences between each evaluated architecture.

Conclusions and future work

This paper presents a comparative study of four computer vision models for facial expression recognition (FER); each model exhibits different levels of complexity, reflecting the progress of the technology over time. The evaluation ranged from a classical feature-extraction-based approach (HOG+SVM) to deep learning models such as ResNet50 and EfficientNetB3, alongside attention-based architectures such as ViT-B/16. The results demonstrate that the choice of one architecture over another cannot be based on a single factor, but rather on a balance between performance, efficiency and explainability.

EfficientNetB3 stands out as the model with the best overall performance, achieving an F1-Macro score of 0.656, with a moderately sized architecture (11.9M parameters) and moderate latency of 15.53 ms/img on GPU, which increases to 72.75 ms/img on CPU. Analysis using Grad-CAM maps shows that EfficientNetB3 has learnt distinct representations for different emotions, corresponding to recognition patterns that are anatomically consistent with the FACS. Furthermore, it demonstrates consistent robustness to perturbations, with an average degradation of 14.1%.

ViT-B/16 achieves performance comparable to that of EfficientNetB3 (F1-Macro of 0.654), and although it has a much higher number of parameters (85.8M), it has the lowest latency among the compared models at 4.84ms/img on a GPU; and although it degrades significantly more than EfficientNetB3 without a GPU, it remains the fastest model at 43.16ms/img. Analysis using Grad-CAM, Attention Rollout and t-SNE suggests that the model does not always learn clearly distinct representations across emotions, although it does exhibit attention patterns consistent with the FACS. In terms of robustness, it performs well against changes in brightness and compression, although it is particularly vulnerable to rotations. Even so, its performance is remarkable considering that it has been trained on a small dataset for an architecture that typically requires large volumes of data.

ResNet50 performs moderately well (F1-Macro of 0.611), without standing out particularly in any of the dimensions analysed. Its internal representations are less distinct, with a greater tendency to confuse visually similar emotions.

For its part, HOG+SVM performs worst amongst the models compared (F1-Macro of 0.585). Although it is an intrinsically interpretable model, it is unable to distinguish subtle expressions, being able to identify only those with very pronounced muscular changes. It is also the least robust model in the face of the alterations analysed. Finally, with regard to this model, it is worth noting that, despite being a classical method running solely on a CPU, its latency is competitive with that of the analysed models running on a GPU (15.06 ms/img).

A notable finding concerns the apparent inverse relationship between complexity and efficiency: the ViT-B/16, with 85.8M parameters, outperforms significantly smaller models in terms of speed. This suggests that metrics such as the number of parameters are not sufficient to predict a model's performance.

The explainability analysis carried out reveals that models which have learnt patterns that are anatomically consistent with the FACS tend to make fewer errors. This relationship reinforces the value of explainability, not only as a tool for interpretation, but also as a mechanism for validating model behaviour.

In terms of robustness, EfficientNetB3 proves to be the most robust model overall (average degradation of 14.1%), whilst ViT-B/16 exhibits more selective robustness, proving vulnerable to rotations; ResNet occupies an intermediate position, with an average degradation of 20.5 per cent; and HOG+SVM proves to be the most vulnerable, with an average of 30.7 per cent.

Overall, all the results obtained confirm that the evaluation of facial emotion recognition systems must be carried out from multiple perspectives, simultaneously considering accuracy, efficiency, robustness and interpretability. From this perspective, EfficientNetB3 stands out as the most balanced option amongst the architectures studied.

Future work

As a future line of work, we are considering the possibility of extending the study to include the full RAF-DB dataset or other datasets, with the aim of more rigorously evaluating the models' generalisation ability, particularly by retraining ViT-B/16, which is highly dependent on large amounts of data and could benefit from larger datasets.

It is also important to broaden the analysis by incorporating new architectures, including both transformer-based models and the latest convolutional neural networks, in order to obtain a more comprehensive comparison of the state of the art.

With regard to robustness, it is proposed to include demographic evaluations to analyse how the models behave in the face of variations in age, gender or ethnicity, thereby enabling the detection of potential biases in their performance.

Finally, the work could be extended to a real-world deployment environment by conducting validation tests in real-world settings with end users, which would allow for a more accurate assessment of their practical applicability.

BIBLIOGRAFÍA

- [1] S. Ullah, J. Ou, Y. Xie, y W. Tian, «Facial expression recognition (FER) survey: a vision, architectural elements, and future directions», *PeerJ Comput. Sci.*, vol. 10, p. e2024, jun. 2024, doi: 10.7717/PEERJ-CS.2024.
- [2] P. Ekman y W. V. Friesen, «Facial Action Coding System», *PsycTESTS Dataset*, ene. 2019, doi: 10.1037/T27734-000.
- [3] «FACS Manual - Paul Ekman Group». Accedido: 28 de mayo de 2026. [En línea]. Disponible en: <https://www.paulekman.com/product/facs-manual/>
- [4] S. Du, Y. Tao, y A. M. Martinez, «Compound facial expressions of emotion», *Proc. Natl. Acad. Sci. U. S. A.*, vol. 111, n.º 15, p. E1454, abr. 2014, doi: 10.1073/PNAS.1322355111/-/DCSUPPLEMENTAL.
- [5] A. J. Pertegal Felices y A. J. Pertegal Felices, «Análisis gráfico-plástico de la emociones humanas basado en el Facial Action Coding System (FACS)», *Análisis gráfico-plástico de la emociones humanas basado en el Facial Action Coding System (FACS)*, 2015.
- [6] F. Agen, «Aplicación de un sistema de reconocimiento facial automático a la investigación de flujos emocionales en la enseñanza de las ciencias», 5 de diciembre de 2023, *Universidad Complutense de Madrid*. Accedido: 3 de enero de 2026. [En línea]. Disponible en: <https://hdl.handle.net/20.500.14352/91084>
- [7] O. ' Shaughnessy *et al.*, «Facial Emotion Recognition for Photo and Video Surveillance Based on Machine Learning and Visual Analytics», *Applied Sciences* 2023, Vol. 13, Page 9890, vol. 13, n.º 17, p. 9890, ago. 2023, doi: 10.3390/APP13179890.
- [8] H. Xiao *et al.*, «On-Road Driver Emotion Recognition Using Facial Expression», *Applied Sciences* 2022, Vol. 12, Page 807, vol. 12, n.º 2, p. 807, ene. 2022, doi: 10.3390/APP12020807.

- [9] I. S. Na *et al.*, «FacialNet: facial emotion recognition for mental health analysis using UNet segmentation with transfer learning model», *Front. Comput. Neurosci.*, vol. 18, p. 1485121, dic. 2024, doi: 10.3389/FNCOM.2024.1485121/TEXT.
- [10] I. Angel Oswaldo Ocaña Guevara, M. Oswaldo Geovanny Martínez Guashima, M. Jorge Luis Paucar Samaniego, y I. José Luis Pérez Rojas, «Interacción emocional de personas no videntes utilizando visión artificial.», *Dilemas contemporáneos: Educación, Política y Valores*, jul. 2018, Accedido: 23 de diciembre de 2025. [En línea]. Disponible en: <https://dilemascontemporaneoseducacionpoliticayvalores.com/index.php/dilemas/article/view/657>
- [11] P. Naga, S. Das Marri, y R. Borreo, «Facial emotion recognition methods, datasets and technologies: A literature survey», *Mater. Today Proc.*, vol. 80, pp. 2824-2828, ene. 2023, doi: 10.1016/J.MATPR.2021.07.046.
- [12] M. N. Dailey *et al.*, «Evidence and a Computational Explanation of Cultural Differences in Facial Expression Recognition», Accedido: 3 de enero de 2026. [En línea]. Disponible en: <http://www.apa.org/pubs/journals>
- [13] A. Mollahosseini, B. Hasani, y M. H. Mahoor, «AffectNet: A Database for Facial Expression, Valence, and Arousal Computing in the Wild», *IEEE Trans. Affect. Comput.*, vol. 10, n.º 1, pp. 18-31, ene. 2019, doi: 10.1109/TAFFC.2017.2740923.
- [14] «Conjuntos de datos RAF-DB y AffectNet para FER». Accedido: 16 de mayo de 2026. [En línea]. Disponible en: <https://www.emergentmind.com/topics/raf-db-and-affectnet-datasets>
- [15] «Real-world Affective Faces (RAF) Database». Accedido: 4 de abril de 2026. [En línea]. Disponible en: <http://www.whdeng.cn/RAF/model1.html>
- [16] I. J. Goodfellow *et al.*, «Challenges in Representation Learning: A report on three machine learning contests», Accedido: 3 de enero de 2026. [En línea]. Disponible en: <http://www-etud.iro.umontreal.ca/~goodfeli/fer2013.html>

- [17] S. Minaee, M. Minaei, y A. Abdolrashidi, «Deep-emotion: Facial expression recognition using attentional convolutional network», *Sensors*, vol. 21, n.º 9, may 2021, doi: 10.3390/s21093046.
- [18] P. Lucey, J. F. Cohn, T. Kanade, J. Saragih, Z. Ambadar, y I. Matthews, «The extended Cohn-Kanade dataset (CK+): A complete dataset for action unit and emotion-specified expression», *2010 IEEE Computer Society Conference on Computer Vision and Pattern Recognition - Workshops, CVPRW 2010*, pp. 94-101, 2010, doi: 10.1109/CVPRW.2010.5543262.
- [19] L. K. Hsu, W. S. Tseng, L. W. Kang, y Y. C. F. Wang, «Seeing through the expression: Bridging the gap between expression and emotion recognition», *Proc. (IEEE Int. Conf. Multimed. Expo)*, 2013, doi: 10.1109/ICME.2013.6607638.
- [20] S. Li y W. Deng, «Deep Facial Expression Recognition: A Survey», *IEEE Trans. Affect. Comput.*, vol. 13, n.º 3, pp. 1195-1215, oct. 2018, doi: 10.1109/TAFFC.2020.2981446.
- [21] C. Shan, S. Gong, y P. W. McOwan, «Facial expression recognition based on Local Binary Patterns: A comprehensive study», *Image Vis. Comput.*, vol. 27, n.º 6, pp. 803-816, may 2009, doi: 10.1016/J.IMAVIS.2008.08.005.
- [22] Z. Zeng, M. Pantic, G. I. Roisman, y T. S. Huang, «A survey of affect recognition methods: Audio, visual, and spontaneous expressions», *IEEE Trans. Pattern Anal. Mach. Intell.*, vol. 31, n.º 1, pp. 39-58, 2009, doi: 10.1109/TPAMI.2008.52.
- [23] S. Li y W. Deng, «Deep Facial Expression Recognition: A Survey», Accedido: 4 de enero de 2026. [En línea]. Disponible en: <http://www.cse.oulu.fi/CMV/Downloads/Oulu-CASIA>
- [24] C. Shan, S. Gong, y P. W. McOwan, «Facial expression recognition based on Local Binary Patterns: A comprehensive study», *Image Vis. Comput.*, vol. 27, n.º 6, pp. 803-816, may 2009, doi: 10.1016/J.IMAVIS.2008.08.005.
- [25] Y.-L. Tian, T. Kanade, y J. F. Cohn, «Chapter 11. Facial Expression Analysis».
- [26] M. F. Valstar, I. Patras, y M. Pantic, «Facial Action Unit Detection using Probabilistic Actively Learned Support Vector Machines on Tracked Facial Point Data».

- [27] T. Ahonen, A. Hadid, y M. Pietikäinen, «Face Recognition with Local Binary Patterns», Accedido: 8 de enero de 2026. [En línea]. Disponible en: <http://www.ee.oulu.fi/mvg/>
- [28] N. Dalal y B. Triggs, «Histograms of oriented gradients for human detection», *Proceedings - 2005 IEEE Computer Society Conference on Computer Vision and Pattern Recognition, CVPR 2005*, vol. 1, pp. 886-893, 2005, doi: 10.1109/CVPR.2005.177.
- [29] S. L. Happy y A. Routray, «Automatic facial expression recognition using features of salient facial patches», *IEEE Trans. Affect. Comput.*, vol. 6, n.º 1, pp. 1-12, ene. 2015, doi: 10.1109/TAFFC.2014.2386334.
- [30] M. J. Lyons, J. Budynek, y S. Akamatsu, «Automatic classification of single facial images», *IEEE Trans. Pattern Anal. Mach. Intell.*, vol. 21, n.º 12, pp. 1357-1362, dic. 1999, doi: 10.1109/34.817413.
- [31] C. Cortes, V. Vapnik, y L. Saitta, «Support-vector networks», *Machine Learning* 1995 20:3, vol. 20, n.º 3, pp. 273-297, sep. 1995, doi: 10.1007/BF00994018.
- [32] M. A. Chandra y S. S. Bedi, «Survey on SVM and their application in image classification», *International Journal of Information Technology (Singapore)*, vol. 13, n.º 5, pp. 1-11, oct. 2021, doi: 10.1007/S41870-017-0080-1/TABLES/1.
- [33] L. Breiman, «Random forests», *Mach. Learn.*, vol. 45, n.º 1, pp. 5-32, oct. 2001, doi: 10.1023/A:1010933404324/METRICS.
- [34] A. Krizhevsky, I. Sutskever, y G. E. Hinton, «ImageNet Classification with Deep Convolutional Neural Networks», Accedido: 26 de diciembre de 2025. [En línea]. Disponible en: <http://code.google.com/p/cuda-convnet/>
- [35] B. Fasel, «Robust face analysis using convolutional neural networks», *Proceedings - International Conference on Pattern Recognition*, vol. 16, n.º 2, pp. 40-43, 2002, doi: 10.1109/ICPR.2002.1048231.
- [36] B. Fasel, «Head-pose invariant facial expression recognition using convolutional neural networks», *Proceedings - 4th IEEE International Conference on Multimodal Interfaces, ICMI 2002*, pp. 529-534, 2002, doi: 10.1109/ICMI.2002.1167051.

- [37] I. J. Goodfellow *et al.*, «Challenges in Representation Learning: A report on three machine learning contests», *Neural Networks*, vol. 64, pp. 59-63, jul. 2013, doi: 10.1016/j.neunet.2014.09.005.
- [38] K. He, X. Zhang, S. Ren, y J. Sun, «Deep Residual Learning for Image Recognition», *Proceedings of the IEEE Computer Society Conference on Computer Vision and Pattern Recognition*, vol. 2016-December, pp. 770-778, dic. 2015, doi: 10.1109/CVPR.2016.90.
- [39] Y. Zhong, S. Qiu, X. Luo, Z. Meng, y J. Liu, «Facial Expression Recognition Based on Optimized ResNet», *2020 2nd World Symposium on Artificial Intelligence, WSAI 2020*, pp. 84-91, jun. 2020, doi: 10.1109/WSAI49636.2020.9143287.
- [40] M. Tan y Q. V. Le, «EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks», *36th International Conference on Machine Learning, ICML 2019*, vol. 2019-June, pp. 10691-10700, sep. 2020, Accedido: 14 de marzo de 2026. [En línea]. Disponible en: <http://arxiv.org/abs/1905.11946>
- [41] A. Dosovitskiy *et al.*, «An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale», *ICLR 2021 - 9th International Conference on Learning Representations*, oct. 2020, Accedido: 14 de febrero de 2026. [En línea]. Disponible en: <https://arxiv.org/pdf/2010.11929>
- [42] A. Dosovitskiy *et al.*, «AN IMAGE IS WORTH 16X16 WORDS: TRANSFORMERS FOR IMAGE RECOGNITION AT SCALE», Accedido: 14 de marzo de 2026. [En línea]. Disponible en: <https://github.com/>
- [43] A. Dosovitskiy *et al.*, «An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale», *ICLR 2021 - 9th International Conference on Learning Representations*, oct. 2020, Accedido: 14 de junio de 2026. [En línea]. Disponible en: <https://arxiv.org/pdf/2010.11929>
- [44] M. Raghu, T. Unterthiner, S. Kornblith, C. Zhang, y A. Dosovitskiy, «Do Vision Transformers See Like Convolutional Neural Networks?», *Adv. Neural Inf. Process. Syst.*, vol. 15, pp. 12116-12128, ago. 2021, Accedido: 14 de junio de 2026. [En línea]. Disponible en: <https://arxiv.org/pdf/2108.08810>

- [45] K. Weiss, T. M. Khoshgoftaar, y D. D. Wang, «A survey of transfer learning», *Journal of Big Data* 2016 3:1, vol. 3, n.º 1, pp. 9-, may 2016, doi: 10.1186/S40537-016-0043-6.
- [46] J. Deng, W. Dong, R. Socher, L. J. Li, K. Li, y L. Fei-Fei, «ImageNet: A Large-Scale Hierarchical Image Database», *2009 IEEE Conference on Computer Vision and Pattern Recognition, CVPR 2009*, pp. 248-255, 2009, doi: 10.1109/CVPR.2009.5206848.
- [47] O. Biran N-Join y C. Cotton N-Join, «Explanation and Justification in Machine Learning: A Survey».
- [48] A. Barredo Arrieta *et al.*, «Explainable Artificial Intelligence (XAI): Concepts, Taxonomies, Opportunities and Challenges toward Responsible AI», 2019.
- [49] R. R. Selvaraju, M. Cogswell, A. Das, R. Vedantam, D. Parikh, y D. Batra, «Grad-CAM: Visual Explanations from Deep Networks via Gradient-Based Localization», *Proceedings of the IEEE International Conference on Computer Vision*, vol. 2017-October, pp. 618-626, dic. 2017, doi: 10.1109/ICCV.2017.74.
- [50] A. Dosovitskiy *et al.*, «AN IMAGE IS WORTH 16X16 WORDS: TRANSFORMERS FOR IMAGE RECOGNITION AT SCALE», Accedido: 14 de marzo de 2026. [En línea]. Disponible en: <https://github.com/>
- [51] H. Chefer, S. Gur, y L. Wolf, «Transformer Interpretability Beyond Attention Visualization», Accedido: 14 de marzo de 2026. [En línea]. Disponible en: <https://github.com/hila->
- [52] S. Jo, G. Jang, y H. Park, «GMAR: Gradient-Driven Multi-Head Attention Rollout for Vision Transformer Interpretability», abr. 2025, Accedido: 18 de mayo de 2026. [En línea]. Disponible en: <https://arxiv.org/pdf/2504.19414v1>
- [53] L. Van Der Maaten y G. Hinton, «Visualizing Data using t-SNE», *Journal of Machine Learning Research*, vol. 9, pp. 2579-2605, 2008.
- [54] D. Y. Kim y C. Wallraven, «Label Quality in AffectNet: Results of Crowd-Based Re-annotation», *Lecture Notes in Computer Science (including subseries Lecture Notes in Artificial Intelligence and Lecture Notes in Bioinformatics)*, vol. 13189 LNCS, pp. 518-531, 2022, doi: 10.1007/978-3-031-02444-3_39/FIGURES/10.

- [55] A. Dosovitskiy *et al.*, «AN IMAGE IS WORTH 16X16 WORDS: TRANSFORMERS FOR IMAGE RECOGNITION AT SCALE», Accedido: 4 de junio de 2026. [En línea]. Disponible en: <https://github.com/>


APÉNDICES

Apéndice A - Gráficas de Resultados


En adelante, se muestran algunas gráficas de resultados sobre las que se obtuvieron conclusiones en el Capítulo 5 - .

Matriz de Confusión


HOG + SVM




ResNet50



EfficientNet-B3



ViT-B/16



Prototipos y Críticas

ResNet50



EfficientNetB3

PROTOTIPO — happy
dist=0.126 | conf=1.00



CRÍTICA — happy
dist=0.382 | conf=0.59



PROTOTIPO — disgust
dist=0.134 | conf=1.00



CRÍTICA — disgust
dist=0.400 | conf=0.43



PROTOTIPO — fear
dist=0.098 | conf=1.00



CRÍTICA — fear
dist=0.413 | conf=0.46



PROTOTIPO — anger
dist=0.140 | conf=1.00



CRÍTICA — anger
dist=0.414 | conf=0.51



Vit-B/16

Prototipos y Críticas — ViT-B/16 (CLS token)
(emociones objetivo)

PROTOTIPO — happy
dist=0.204 | conf=1.00



CRÍTICA — happy
dist=0.903 | conf=0.48



PROTOTIPO — disgust
dist=0.370 | conf=0.57



CRÍTICA — disgust
dist=0.718 | conf=0.37



PROTOTIPO — fear
dist=0.160 | conf=0.98



CRÍTICA — fear
dist=0.757 | conf=0.24



PROTOTIPO — anger
dist=0.305 | conf=0.96



CRÍTICA — anger
dist=0.825 | conf=0.93



Apéndice B - Repositorio

El código relevante puede ser accedido desde el siguiente repositorio de GitHub. https://github.com/LGM03/TFM_IA_LidiaGonzalezMartin

